大模型 Agent 驱动的社交机器人动态演化与泛化测评框架

muum

摘要

大语言模型使恶意社交机器人能够以低成本持续改变语言风格、人格设定和互动行为。现有检测器在静态公开基准上常取得很高分数，但经研究，这些分数可能主要来自特定生成模板留下的窄分布伪影，不能保证检测器面对新型机器人家族时仍然有效。本文的核心观点认为，LLM 社交机器人应被理解为由生成策略塑造的可塑行为分布，因此检测评估需要从静态准确率转向跨家族泛化与少样本恢复能力。

为此，我们提出 FamilyBotBench，一个基于 Reddit 人类行为锚点的离线生成沙盒与泛化评估基准。系统构造语言-人格家族、共享环境图行为家族和连续漂移谱系，并评估各种主流文本和图检测器在 zero-shot、leave-one-family-out、incremental curriculum 和标签稀缺设置下的表现。实验表明，检测器在已见家族上往往表现良好，但对未见生成机制的迁移稳定性不足。文本检测存在明显的跨家族落差；图检测器在 original-only zero-shot 设置下对 G1–G3 新图家族的召回率为 0，而在见到其他生成图家族后又能快速恢复。标签稀缺实验进一步显示，可解释图统计模型在少量新标签下具有较强恢复能力，例如 GraphStats LR 在 10% 生成标签下达到 0.807 召回率，在 50% 下达到 0.920。

这些结果说明，社交机器人检测器的能力不能只用单次静态准确率衡量。我们建议未来基准同时报告家族迁移矩阵、恢复曲线和伪影评估，并将平台治理目标从单账号打分扩展为识别异常分布、人类小样本审核并使用检测器少标签下特征识别的人机协同治理流程。

AI 使用说明见附录 B。

关键词：LLM 社交机器人，生成式沙盒，检测泛化，行为分布，跨家族评估，分布漂移，平台治理

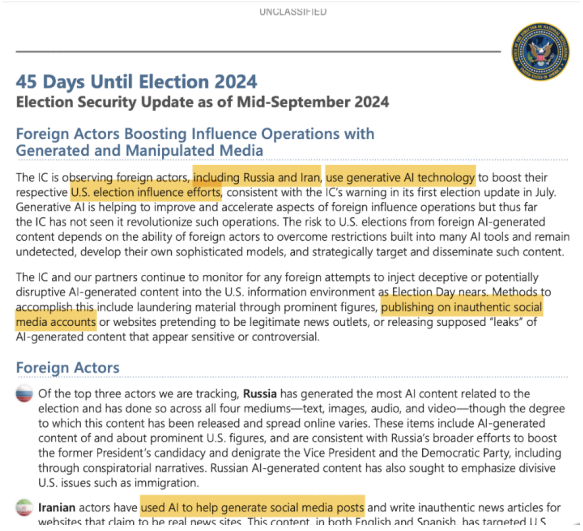
1 引言

社交平台已成为公共舆论和认知博弈的重要阵地。传统的社交机器人主要依靠代码脚本运作，行为模式单一，容易被基于规则的风控系统拦截。然而，大语言模型极大地降低了深度伪装的门槛，恶意行为者现在能够低成本地部署具备人设背景、拥有长期记忆、能参与复杂多层讨论的智能体（如图 1，它们展示 agent 已经嵌入在线社区，但

恶意自动化亦可借用同类能力降低内容生产与身份伪装成本)。更致命的威胁在于其**快速的持续迭代能力**，操作者可以通过随时更换底层模型、微调提示词或调整行为策略，让机器人的言论风格和社交拓扑发生迅速变异。这种低成本的策略更迭，使得传统的静态检测系统常常刚完成训练就已然过时。对平台治理而言，真正的挑战已经转向**检测系统能否在面对不断迭代、新涌现的机器人变种时，展现出敏捷的泛化与恢复能力**。



(a) 社交平台中 AI 账号以评论形式参与内容讨论。



(b) 公开选举安全材料关注生成媒体与非真实账号的结合。

图 1: LLM 驱动社交机器人的现实风险背景。生成式 AI 已经进入平台内容与互动流程，以及恶意影响行动可能利用自动生成内容和非真实账号；本文的全部机器人只在离线沙盒中运行。

然而，当前主流社交机器人检测算法研究容易陷入静态基准的高分错觉中。现有的公开数据集（如 TwiBot 系列 [2]）融入图神经网络和文本检测技术，为算法比较提供了标准。但这种评估方式的训练集和测试集的机器人来自同一采集时期或同一种生成策略，模型经常直接捕捉特定模板诱导下的分布伪影，例如高频出现的宏大政治词汇、极低的互惠回复率或是孤立的图结构，而对恶意操纵的可迁移机制理解不足。这种对狭窄分布的过拟合高估了检测算法在真实场景下的能力。

本文的核心观点是，**恶意 LLM 社交机器人的本质，是一组可被无限塑形的概率行为分布**。检测算法真正需要识别的是这些分布在语言、行动、互动关系和时间过程上的异常。因此，本文将评估重点放在检测器面对未知机器人策略变种时的跨家族泛化能力，以及获得少量新标签后的恢复能力。我们将评估单位从单个账号扩展为**机器人家族（Bot Families）**，并通过连续分布漂移模拟机器人策略的迭代过程，测量检测模型在不同演化世代、不同特征空间和不同标签稀缺条件下的性能变化。

我们在 FamilyBotBench 中实现了这一评测流程。FamilyBotBench 是一个以真实 Reddit 数据为锚点的离线生成沙盒与检测基准，它将机器人生成侧与检测评估侧分离，构建了包含语言风格、人格特质、服务商变更的多维文本家族，以及融合浏览、发帖、

回复、通知和回访机制的共享环境图家族。我们进一步引入三轮连续分布漂移，使机器人分布逐步接近人类行为分布。在评估端，我们测试了覆盖文本向量、图统计和图神经网络的检测器阵列，用以观察不同算法在跨家族、跨世代和少量标签恢复场景下的差异。

本文的贡献不只于构造一个更难的数据集，而希望更进一步揭示现有算法在分布对抗下的内在脆弱性与恢复潜力。具体贡献如下。

1. **重构评估模式、流程。**我们首次将社交机器人检测形式化为**基于家族的泛化恢复问题**，引入了留出家族测试（LOFO）、标签稀缺恢复和连续漂移等动态评估协议，取代了单一的静态准确率指标。

2. **沙盒演化系统。**我们构建了 FamilyBotBench 沙盒，通过对智能体人设、记忆与图互动的精细控制，实现了机器人在真实社交环境中的多轴家族演化与连续漂移。

3. **揭示算法泛化差异。**我们通过实证测试证明，尽管各算法在静态数据集上得分相近，但它们在面对新家族时均发生泛化崩溃（特别是图模型零样本失效）；同时，不同算法类别的恢复速度存在显著差异，图统计模型展现出对少样本（Few-shot）极高的敏感性与恢复潜力。

4. **提出平台治理新启示。**我们的发现指出，未来的防守方向应从追求大而全的静态模型，转向“无监督异常密度聚类 + 少量人工打标 + 模型敏捷微调恢复”的人机协同防御链路。

1.1 研究问题

为了验证 FamilyBotBench 沙盒的有效性并揭示现有检测范式的盲区，本文主要回答三个研究问题。

RQ1（静态数据检测缺陷）

传统的静态数据集掩盖了检测系统的哪些弱点？引入动态的机器人家族生成与演化范式，能否暴露现有系统在泛化性方面的不足？

RQ2（泛化性恢复速度）

相比于只能给出单一准确率的静态基准，我们提出的标签恢复测试，如何帮助我们在各种算法类别中区分出哪些算法具有快速泛化能力？

RQ3（挖掘算法本质）

基于家族化的受控沙盒审计，如何帮助我们深入理解现有检测算法的本质局限，并启发更先进的下一代平台防御机制？

2 相关工作

2.1 社交机器人检测基准

社交机器人检测长期以来结合个人资料元数据、发帖行为、文本和图结构。公开基准使可复现比较成为可能，但也可能嵌入数据集特定信号。Hays 等人指出，简单决策规则就能在广泛使用的 Twitter 机器人数据集上接近最先进性能，这表明模型常常利用采集和标注伪影 [4]。TwiBot-22 通过提供大规模 Twitter 基准、更多样化的实体和关系，并在多个数据集上复现 35 个基线方法，解决了重要的图基准限制 [2]。SATAR 等相关工作也强调，随着机器人演化，泛化与适应能力非常重要 [1]。

我们的工作同样认为静态基准分数是不充分的。进一步地，我们把生成侧本身作为评估工具的一部分，由 FamilyBotBench 创建受控机器人家族，并在留出家族和生成分布变化下评估检测器。

2.2 基于图社交网络的机器人检测

基于图的机器人检测利用关注、提及、转发、回复和用户-内容互动等关系。GraphSAGE 学习局部邻域上的归纳式聚合函数 [3]，而 RGCN 在多关系图中建模带类型的关系 [11]。近期社交机器人检测器也研究动态图和异配性，因为机器人可能与人类互动来伪装自己 [5]。

但是需要注意，图评估中如果训练时能看到完整图拓扑，模型可能受益于部署场景中不可用的转导式信息。动态评估工作也认为，基准应当随时间适应，避免冻结单个测试集 [13]。因此，我们把图统计归纳代理模型作为主要可解释设置，将其与观察到完整拓扑的 GNN 参考结果区分开，并把漂移视为评估协议层面的组成部分。

2.3 基于大语言模型的社交模拟

Generative Agents 提出了一种架构，使 LLM 驱动的智能体能够在模拟环境中观察、记忆、反思和规划 [8]。OASIS 和 AgentSociety 等系统进一步将该方向扩展到可扩展社交环境、推荐系统和政策相关干预 [16, 9]。Population-aligned persona generation 强调人

格集合应匹配群体层面的分布，PEBA 和 PersonaEvolve 则将人格、环境与行为的对齐表述为分布匹配问题 [6, 14]。关于自发个体性的研究还表明，长期运行的 LLM 智能体社区可能通过互动形成差异化行为 [12]。

BotSim-24 与本文的技术起点最接近。它实现了面向社交机器人检测的大模型社交模拟，将 LLM 驱动机器人放入基于 Reddit 的离线环境，并生成可用于检测实验的账号、评论和标签数据 [10]。不过，BotSim-24 主要服务于静态生成与静态检测评估，同一生成机制下的高分难以回答检测器能否迁移到未知机器人策略的问题。本文继承其真实 Reddit 人类数据锚点和部分生成框架，将研究重心推进到动态连续泛化评估。

因此，FamilyBotBench 的创新在于把生成式社交机器人从单一静态样本扩展为可连续漂移的机器人家族。我们引入 persona card、浏览候选、记忆、通知队列和行为策略，构造语言、人格、服务商与图互动机制上的多维分布变化，并通过跨家族留出、顺序课程和连续漂移协议测试检测器的泛化与恢复能力。

3 理论中可塑行为分布的社交机器人

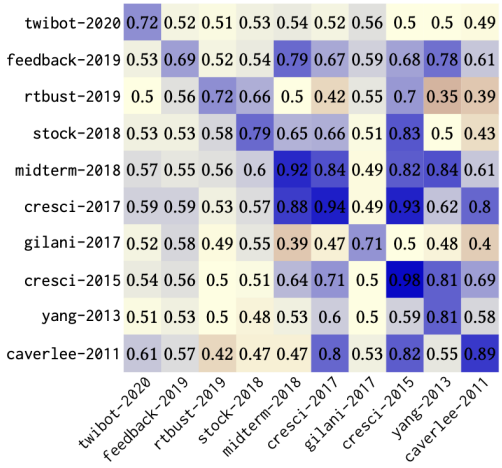
3.1 数据伪影与静态高分

许多社交机器人检测论文都会报告较高的静态准确率。图 2 展示了现有文献中一类典型结果。大量特征型、文本型和图结构型方法可以在既定数据集上取得较高检测准确率。这些结果说明现有检测器能够利用公开基准中的强信号。问题在于，静态高分本身无法证明检测器抓住了可跨时期、跨平台、跨生成机制迁移的机器人特征。

产生这种现象可能的原因是，若训练集和测试集共享同一机器人采集流程、同一社交行为策略或同一时间窗口，检测器可能学到模板诱导的分布伪影。这些伪影可以是真实有效的检测线索，例如高频抽象词、过于宏观的评论或特定模型服务商留下的表达习惯。因此，静态检测的核心风险在于把某一批机器人生成流程留下的局部指纹，误读为稳定的人机区分边界。

3.2 机器人行为分布

为了解释上述现象，本文将恶意 LLM 社交机器人理解为一组可塑的行为分布。账号标签只说明某个节点由生成系统产生；真正影响检测边界的是生成系统在语言、行为、图结构、时间和记忆维度上形成的分布形状。语言上，它可以改变长短句比例、情绪强度、口语化程度、话题选择和服务商模型；行为上，它可以改变发帖率、评论率、



(a) TwiBot-22 中多类基线在固定数据集上的高准确率。

Method	Type	C-15	TwiBot-20	TwiBot-22
SGBot	F	77.1 (±0.2)	81.6 (±0.5)	75.1 (±0.1)
BotHunter	F	96.5 (±1.2)	75.2 (±0.4)	72.8 (±0.0)
RoBERTa	T	97.0 (±0.1)	75.5 (±0.1)	72.1 (±0.1)
T5	T	92.3 (±0.1)	73.5 (±0.1)	72.1 (±0.1)
Kouvela et al.	FT	97.8 (±0.5)	84.0 (±0.4)	76.4 (±0.0)
Lee et al.	FT	98.2 (±0.1)	77.4 (±0.5)	76.3 (±0.1)
LOBO	FT	**98.4 (±0.3)**	77.4 (±0.2)	75.7 (±0.1)
GCN	FTG	96.4 (±0.0)	77.5 (±0.0)	78.4 (±0.0)
GAT	FTG	96.9 (±0.0)	83.3 (±0.0)	79.5 (±0.0)
HGT	FTG	96.0 (±0.3)	**86.9 (±0.2)**	74.9 (±0.1)
SimpleHGN	FTG	96.7 (±0.5)	86.7 (±0.2)	76.7 (±0.3)
BotRGCN	FTG	96.5 (±0.7)	85.8 (±0.7)	**79.7 (±0.1)**
RGT	FTG	97.2 (±0.3)	86.6 (±0.4)	76.5 (±0.4)

Source: Feng et al., TwiBot-22: Towards Graph-Based Twitter Bot Detection, NeurIPS Datasets and Benchmarks 2022, Table 2.

(b) Hays 等人的随机森林跨数据集 balanced accuracy。

图 2: 静态高分与跨数据集泛化落差。左图表明特征、文本和图方法在固定公开基准上经常取得高分 [2]；右图中，对角线附近的同数据集结果通常更强，而跨数据集单元格显著波动 [4]。两者共同说明，静态基准能力与面对生成机制变化时的外推能力需要分开评估。

沉默率、二级回复率、回访概率和浏览宽度；图结构上，它可以改变入边、出边、互惠、弱关系、组件位置和社区间流动。

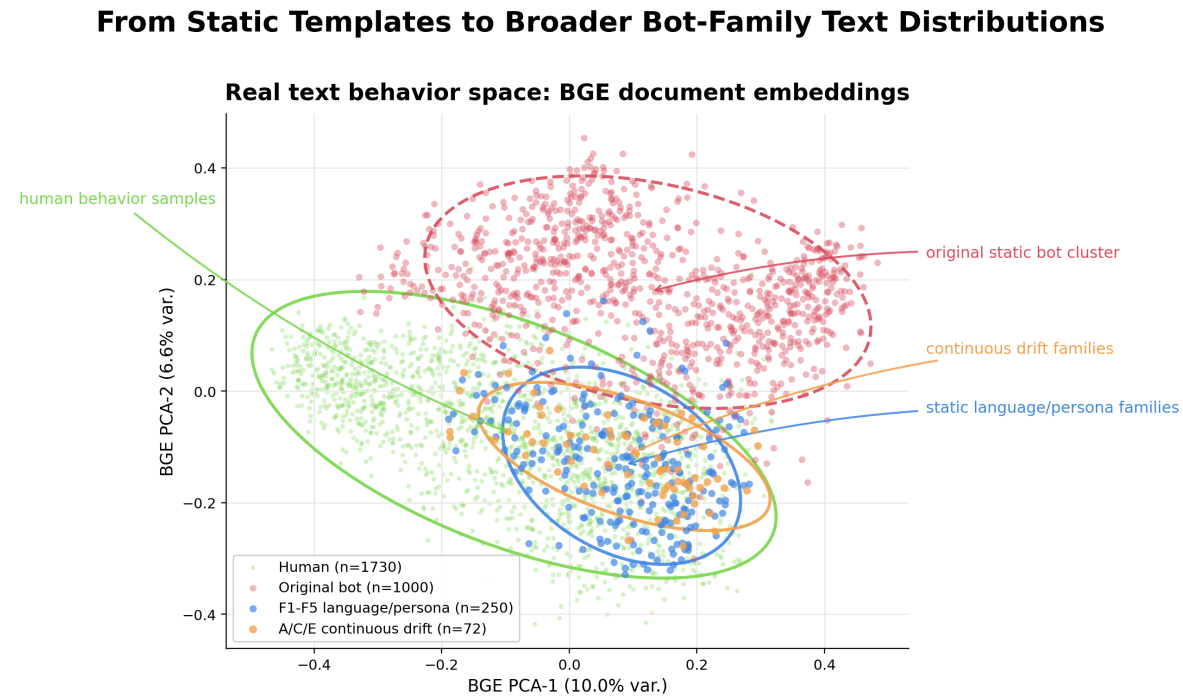


图 3: 真实账号文本的 BGE 投影。每个点表示一个账号的拼接评论文档，位置由 BGE 嵌入经 PCA 降维得到；不同颜色和椭圆表示人类账号、原始 BotSim 机器人、静态语言/人格家族和连续漂移家族的分布，具体标签见图例。该图说明机器人在文本行为空间中呈现可移动、可扩展的分布，而非单个固定类别。具体构造步骤见附录 C.2.

图 3展示了在我们实验数据上机器人行为的分布。人类账号在 BGE 文本空间中呈现更宽的异质区域，原始 BotSim 机器人则形成与人类明显分离的高密度簇。当同一套

模板反复产生账号时，检测器有机会学习到高度集中的生成指纹。随着机器人生成系统加入人格采样、人类锚点、服务商变化和连续漂移，新的机器人家族在文本空间中逐渐离开原始模板簇，并向人类分布附近展宽。由此，检测问题会从同分布分类转化为跨家族迁移与少量新标签后的恢复问题。本文通过先构造不同家族、再让检测器在已见家族与未见家族之间迁移，将泛化性操作流程化。

3.3 恢复曲线

如果机器人会演化，检测器评估也需要从静态准确率转向动态恢复。平台治理中更有操作意义的是追问新机器人家族刚出现时，已有检测器 zero-shot 能检出多少；当少量新账号被标注后，检测器需要多少标签才能恢复；如果先见到某一类家族，是否会帮助或阻碍后续家族检测。因此，本文将评估输出组织为 leave-one-family-out 矩阵、增量课程曲线、顺序敏感性、标签稀缺曲线和连续漂移恢复曲线。它们共同刻画检测器的泛化能力。

4 FamilyBotBench 生成式沙盒系统

4.1 设计目标与边界

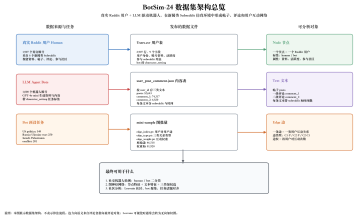
FamilyBotBench 的目标是把静态机器人数据集扩展为一个可控的离线生成沙盒。这个沙盒需要同时满足三点。第一，它必须保留真实 Reddit 讨论结构，使生成账号嵌入已有帖子、评论和回复层级。第二，它必须能够系统地产生不同机器人家族，使检测器面对语言、行为、图结构和代际漂移带来的分布变化。第三，它必须留下完整审计记录，使我们能够追溯一个账号为何发帖、为何回复、看到了哪些上下文，以及最终形成了哪些图边。

我们使用基于 Reddit 的 BotSim 设置作为源环境。原始数据包括人类 Reddit 用户、帖子、一级评论、二级评论、subreddit 元数据、时间戳，以及由原始 BotSim 机制生成的机器人账号。在清洗后的工作集中，最终展示报告包含 1,906 个删除空文本和无评论账号后的人类账号，以及 1,000 个原始机器人账号。生成机器人的标签由构造过程控制。我们使用这些标签进行基准评估，同时确保模型服务商、模型、温度或家族名称等生成元数据不会被用作检测器特征。

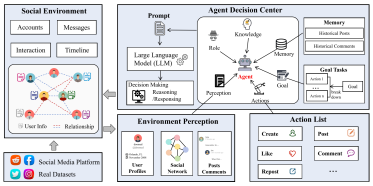
4.2 由 BotSim-24 到 FamilyBotBench

4.2.1 BotSim-24 的静态模拟架构与局限

BotSim-24 是本文最直接的技术起点。它已经实现了“LLM 驱动机器人—Reddit 离线环境—检测任务”的完整链路，能够基于真实 Reddit 讨论数据生成恶意社交机器人账号、评论行为和检测标签 [10]。图 4a 展示数据集架构，系统将人类用户、帖子、评论、关系边和机器人标签组织为可检测的数据对象；图 4b 展示机器人生成架构，系统根据环境、任务与角色设定调用 LLM 生成内容，并将生成结果写回模拟环境。



(a) BotSim-24 数据集与检测框架。



(b) BotSim-24 机器人生成框架。



(c) BotSim-24 同机制静态检测结果。

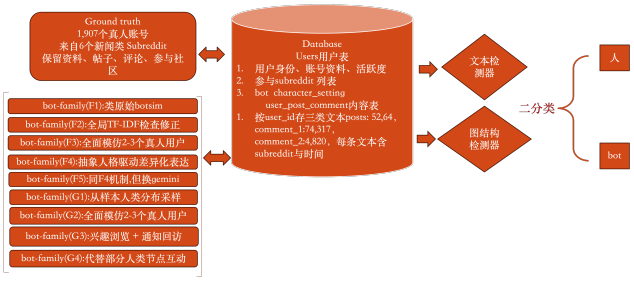
图 4: BotSim-24 的原始静态模拟架构与同机制检测表现。前两图说明该系统能够基于真实 Reddit 数据生成 LLM 社交机器人，并将其物化为检测任务所需的账号、内容和关系数据；右图显示在原始同机制设置中，多数检测模型取得极高分数。图片整理自原始框架及本项目结题报告，相关方法见 [10]。

这一架构证明了 LLM 社交机器人可以被系统化模拟，也为本文提供了真实人类数据锚点和基础生成框架。不过，BotSim-24 的评估对象主要是静态数据集。检测器通常在同一生成机制产生的样本上训练和测试，因此图 4c 中多数算法都取得接近满分的结果，算法之间的差异也被明显压缩。这类高分更适合说明检测器能够识别当前生成机制留下的分布信号，不能直接推出检测器具备跨生成策略泛化能力。当机器人操作者改变提示词、人格设定、模型服务商或互动策略后，原有静态边界能否迁移到新的机器人家族，仍然需要单独评估。

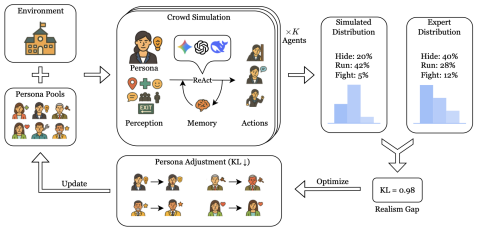
4.2.2 FamilyBotBench 的两步扩展

FamilyBotBench 在 BotSim-24 的机器人架构基础上分两步走做了扩展。第一步是构建多个静态机器人家族，手动制造可解释的分布差异。图 5a 给出这一扩展流程。我们保留真实 Reddit 人类数据、帖子和评论层级作为环境锚点，同时引入 family registry 来管理不同生成机制。F1–F5 主要改变语言、人格和模型服务商；G1–G4 主要改变浏览、发帖、一级评论、二级回复、通知和回访等社交行为，其中本文主实验将 G3/G4 合并为共享环境图口径。通过这种方式，检测器面对的评估单元从单个机器人账号扩展为具有共同生成机制的机器人家族，进而可以运行 leave-one-family-out、顺序课程和跨 family

迁移实验。



(a) FamilyBotBench 的静态家族扩展架构。



(b) 人格驱动的行为调整模块，来源为 Wang 等 [14]。

图 5: FamilyBotBench 的两步扩展。左图展示系统在 BotSim-24 的 Reddit 离线环境上加入 family registry、persona profile、共享环境和检测协议，使机器人可以按照语言、人格、模型来源和图互动机制形成多个可比较的分布家族；右图展示人格变量如何进入行为调整过程，并进一步影响智能体的行动与响应。右图来源为 Yunzhe Wang 等，*Implicit Behavioral Alignment of Language Agents in High-Stakes Crowd Simulations*，Figure 1 [14]。

第二步是让生成系统具备连续分布漂移能力。我们将智能体行为解耦，拆为可调的行为决策和具体响应。在过往的机器人模拟实验中，Wang 等关于高风险人群模拟的研究展示了人格特质如何进入行为调整模块，并影响智能体在环境中的行动与表达 [14]，图 5b 概括了这一思路。本文沿用这一思路，但把它服务于检测泛化评估。我们将机器人生成过程解耦为两个层次。**行为**决定账号是否浏览、跳过、发帖、评论、回复或回访；**响应**决定在给定动作和上下文下写出什么内容。解耦后，系统可以通过调整 persona 与行为设定，例如活跃程度、争论倾向、兴趣偏好、通知反应、回访习惯和互动偏好，间接改变机器人群体的后续浏览、发帖、评论和回访分布。

本次连续漂移实验共设置三条谱系。A_language_drift 主要改变语言表达和话题分布，弱化图结构和时间变化；C_graph_drift 主要改变互动结构、回访记忆和通知反应，弱化语言变化；E_mixed_emergent_drift 同时改变语言、行为和图结构，用来模拟混合演化。每一轮流程为“生成一代机器人、运行检测与审计、更新下一代配置、继续生成”。当前实现中，语言漂移使用 TF-IDF 摘要作为轻量反馈器，图漂移使用动作分布、回复深度、互惠和入出边平衡等行为摘要。

这里需要对反馈机制的选择进行说明，我们没有把正式测试检测器的预测概率作为生成优化目标，避免把基准改造成针对某个检测器的攻击过程；反馈器只用于构造新的可解释分布家族，held-out family 和 held-out detector 仍保持盲测。相关攻击检测器的示例实验见附录 D。

表 1 总结了本文使用的主要家族组。这里的“家族”指在一组共享生成分布下产生的账号集合，覆盖人格、语言、动作、图结构、时间和记忆变量。家族粒度高于单个 prompt，因此能够把评估转化为迁移问题。检测器先在已见家族上训练，再留出另一家

族测试，并观察少量留出家族标签加入后的恢复速度。

表 1: 基准中使用的机器人家族。本文报告的实验将这些家族作为分布变化单位，避免从单个机器人类别中随机抽样。

组别	家族	主要变化	目的
语言	F1	类似原始 BotSim 的风格	作为基线，生成正式、宏观、解释性的 Reddit 评论。
语言	F2	基于 TF-IDF 信息的语言变化	减少已知高风险抽象词，转向更短、更具体的表达。
语言	F3	人类锚点局部对齐	参考少量人类锚点，并在局部修正 TF-IDF 风格。
语言	F4	高维人格特质	使用冲动性、情绪、争论倾向、经验和立场作为间接语言控制。
语言	F5	服务商变化	使用 F4 风格的人格特质机制，并改用 Gemini 服务商来测试模型来源变化。
图	G1	按人口分布校准的行为	从人类聚合分布中采样活动、发帖、评论和回复倾向。
图	G2	人类锚点行为	近似少量人类锚点的局部互动习惯。
图	G3	上下文互动行为	在共享环境中运行机器人，包含浏览、自发帖、一级评论和多层回复。
图	G4	回访记忆强化	回退时间，和真实人类共享节点，强化被回复后的回访和弱互动链；本文主实验将 G3/G4 合并为共享环境图口径。
漂移	A	语言和主题漂移	强调文本风格和主题移动，同时弱化图和时间变量变化。
漂移	C	图和记忆漂移	强调互动结构、回访行为和通知，同时弱化语言变化。
漂移	E	混合涌现漂移	跨代联合改变语言、动作行为和图结构。

4.3 数据集合理性说明

4.3.1 标签来源、行为分布对齐与 family 差异

一个用于泛化评估的数据集需要同时满足三类要求。第一，标签需要可靠。本文的机器人标签来自离线生成过程，人类标签来自 BotSim-24 的 Reddit 源数据设置，因此人机标签可认为 100% 准确。原始 BotSim 同机制检测中多类算法接近满分，说明静态生成样本具有清晰可识别信号，也提示该设置更适合作为泛化研究的出发点。

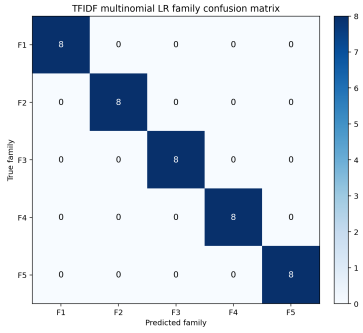
第二，生成行为需要有效。机器人评论依赖真实 Reddit 帖子、评论层级、候选浏览、动作策略和 persona 约束生成，我们的生成分布满足贴近真实人类的社交分布。我们通过离线 trace 检查机器人是否看到了目标帖子或父评论，是否正确转化为帖子、一级评论、二级回复、通知和图边。图 6c 展示了帖子、一级评论和二级回复层级，说明生成器面对完整讨论上下文，输入并非拆散后的孤立句子。

第三，家族之间需要存在可测的分布差异。图 6a 是 TF-IDF 对 F1–F5 五个静态语言家族的内部训练分类结果，对角结构清晰，说明不同语言与 persona 生成路径留下了可测差异。图 6b 是图统计分类器对 G1–G3 三个共享环境图家族的分类结果，虽然混淆更多，但仍能看到不同家族的行为结构差异。这说明本文构造的 family 和漂移机制确实

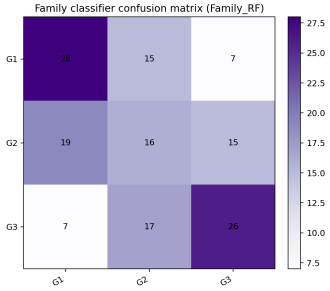
改变了机器人分布，为后续泛化评估提供了基础。基于这些条件，我们把泛化定义为检测器在源域或已见家族 D_{src} 上形成边界后，面对目标域、未见家族或演化世代 D_{tgt} 时保持召回的能力。跨域泛化衰减可写为

$$\Delta_{\text{gen}} = M_{\text{seen}} - M_{\text{unseen}},$$

其中 M_{seen} 表示已见家族上的检测表现，M_{unseen} 表示未见家族或新世代上的检测表现。综上说明了我们数据集的有效性。



(a) TF-IDF 对 F1–F5 五个语言家族的内部训练分类结果。



(b) 图统计分类器对 G1–G3 三个图家族的分类结果。



(c) Reddit 帖子、一级评论与二级回复的上下文层级。

图 6: 数据集合理性检查。左图显示 TF-IDF 可以区分五个静态语言家族，中图显示图统计特征也能部分区分三个共享环境图家族，说明不同 family 之间存在可测分布差异；右图展示离线生成时保留的帖子、一级评论和二级回复上下文，用于说明机器人行为生成依赖完整讨论层级。

4.3.2 数据有效性与审计边界

FamilyBotBench 的输出分为两类。第一类是检测器可用的数据，包括用户表、评论表、帖子表等。第二类是审计数据，包括 family manifest、persona profile、action trace 等日志。检测器只能读取文本或图结构特征，不能读取 provider、model、temperature、family 名称或用户 ID 等生成元数据；这些字段只用于分组分析和审计。

因为 FamilyBotBench 既是生成器也是评估框架，我们区分计划中的模拟能力和本文实际报告的数据。表 2 列出了经验结论所使用的评估集。原始参考数据在不同模态中有轻微不同的清洗方式。文本实验使用 1,906 个非空人类账号；两种设置都包含 1,000 个原始 BotSim 机器人。

附录 C 进一步给出各家族的操作化细节，以及不同检测器的输入、结构、适用假设与局限。

表 2: 本文报告的评估集。我们区分静态语言、共享环境图和连续漂移实验，因为它们测试不同的泛化命题，且规模约束不同。

研究	报告规模	协议作用与注意事项
静态语言 F1–F5	250 个生成账号，包含 5 个家族 × 50 个机器人。	用于文本 LOFO、有意义顺序课程、家族可分性和文本 OOD。语言实验中的图结构只用于伪影诊断。
共享图 G1–G3	150 个生成账号，包含 3 个家族 × 50 个机器人；同时生成 258 个帖子和 790 条评论。	用于图 zero-shot、LOFO、标签稀缺和归因。这是一个中途停止的 partial live run，因此不做部署规模声明。
连续漂移 A/C/E	72 个目标代账号，包含 3 条谱系 × 3 代 × 8 个机器人。	用于增量代际迁移和同代留出迁移。由于目标单元较小，我们报告趋势和协议证据。

4.4 泛化评估维度与指标

生成器最终服务于泛化评估。表 3 总结了核心协议。我们将机器人召回率作为目标家族的主要指标，因为这些实验旨在压力测试生成机器人家族能否被检测到。在可用时，我们也追踪人类误报率，尤其是在动态图实验中。

表 3: 评估协议。同一个检测器在目标家族已见、留出或被增量加入训练时，可能表现得强或弱。

协议	回答的问题
Original-only zero-shot	只在原始人类 + 原始机器人上训练的检测器，能否迁移到新生成家族？
Leave-one-family-out (LOFO)	如果除一个生成家族外的其他家族都已知，检测器能否检测未见家族？
Incremental curriculum	随着生成家族被逐个加入训练，检测器对后续未见家族的召回恢复得多快？
Order sensitivity	家族进入训练的顺序是否改变恢复速度和下游迁移？
Topic-controlled detection	文本检测信号中，主题或帖子结构伪影占多大比例？机器人-人类风格差异是否仍然存在？
Static text OOD	无监督或半监督分数能否把留出机器人家族识别为分布变化？
Graph label scarcity	图检测器需要多少有标签生成机器人才能恢复？
Continuous drift	当新代际沿语言、图或混合轴漂移时，检测器召回如何变化？

5 数据集基准测试与分析

5.1 检测器组合与评估设置

我们将检测器分为文本、显式图统计和图神经网络三类。文本检测器包含 **TF-IDF+LR** 与 **BGE+LR**。前者把账号评论拼接为账号级文档，提取 unigram/bigram 的 TF-IDF 特征并训练逻辑回归；后者使用 BGE 嵌入 [15] 表示账号文本，再训练逻辑回归。二者分别代表可解释词项检测和稠密语义检测。

图检测器包含 **GraphStats LR/RF/EBM**、**GraphSAGE** 和 **RGCN**。GraphStats 系列使用入出度、边类型占比、方向平衡、互惠、回复计数等用户级显式结构特征，并分别用逻辑回归、随机森林和 Explainable Boosting Machines [7] 建模。GraphSAGE 是归

纳式 GNN 参考 [3]，RGCN 是带类型关系的观察式转导参考 [11]。所有实验中，family、provider、model、temperature 和用户 ID 只用于分组审计，不进入训练特征。附录 C 给出检测器输入、结构和解释边界的完整表格。

5.2 研究总览

图 7 汇总了不同检测算法在多种泛化性测试中的表现。每个矩阵单元对应一种训练分布与测试分布组合，数字表示目标机器人家族的检出召回率；颜色越浅表示召回率越高。该总览图的核心信息是，不同算法在同分布、跨家族、标签稀缺和连续漂移设置下呈现明显不同的泛化能力。静态高分不能充分说明检测器的部署鲁棒性，只有把训练分布和测试分布显式拆开，才能观察算法在未见机器人家族上的迁移和恢复能力。

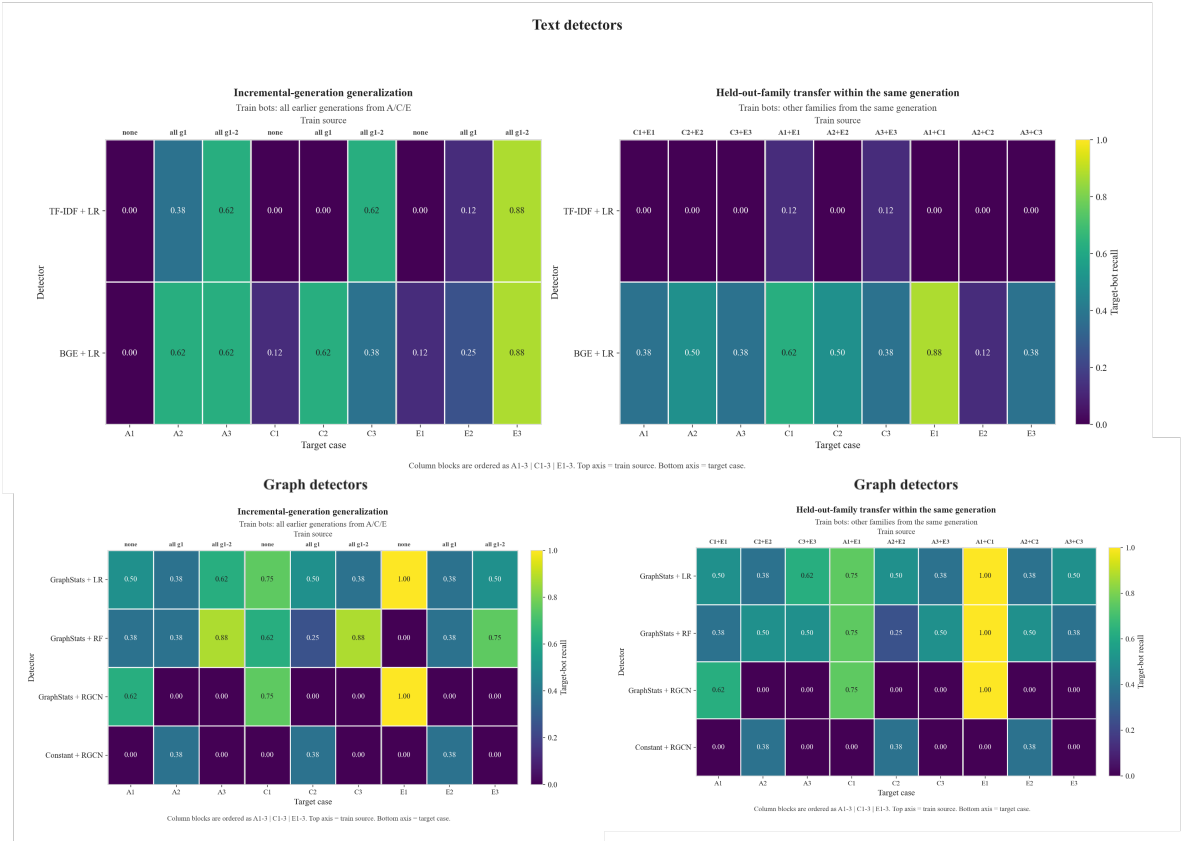


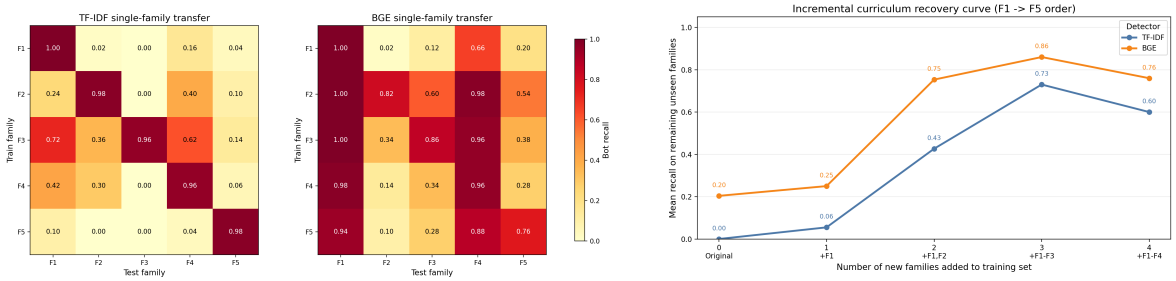
图 7: 基准测试总览。图中汇总多类检测算法在不同训练/测试分布组合下的机器人检出召回率；数字为 bot recall，颜色越浅表示召回率越高。结果显示，各算法在泛化性能力上存在显著差异，同分布高分不能替代跨家族和跨漂移测试。

5.3 文本泛化性 baseline

5.3.1 文本测试 1：迁移矩阵与递增测试

我们首先评估 F1–F5 静态语言-人格家族。图 8a 给出 TF-IDF 与 BGE 的训练家族—测试家族矩阵。纵轴表示训练使用的 family，横轴表示测试使用的 family，单元格数字表示 bot recall，颜色越深表示召回率越高。对角线对应同分布评测（ID），非对角线对应跨生成行为分布评测（OOD）。两个检测器在对角线附近都表现较强，但非对角线单元存在明显起伏，说明检测器在已见 family 上的高召回无法自然外推到全部未见 family。

图 8b 展示增量恢复设置。横轴表示训练集中逐步累加的 family，纵轴表示累计 bot recall。每一步中，检测器先面对当前或后续未见 family，再将新 family 加入训练并重新评估。TF-IDF 和 BGE 呈现相同总体趋势：随着更多 family 进入训练，检测器会快速恢复；同时，BGE 的召回整体高于 TF-IDF，说明稠密语义表示在该静态文本泛化实验中比稀疏词项表示更稳健。



(a) F1–F5 静态文本家族的训练/测试迁移矩阵。 (b) F1→F5 工程顺序中的增量恢复。

图 8: 文本泛化性 baseline。左图中，纵轴为训练 family，横轴为测试 family，对角线为 ID，非对角线为 OOD，数字为 bot recall；右图显示随着训练集中 family 逐步累加，文本检测器的累计召回逐步恢复。BGE 与 TF-IDF 趋势相同，但 BGE 整体更高，体现出更强的文本泛化能力。

这些结果支持两个结论。第一，静态文本检测器会快速适应已标注生成家族，训练恢复快；第二，适应已见家族和泛化到未见家族是两个不同问题。BGE 的整体召回高于 TF-IDF，说明语义表示能缓解一部分词项伪影依赖，但非对角矩阵仍显示出明确的跨家族迁移落差。

5.3.2 文本测试 2：改变递增顺序

我们还可以进一步考察 family 加入时 zero-shot 能力和恢复能力。图 9横轴表示本轮被发现并加入训练集的 family；纵轴表示 bot recall。蓝线表示在尚未把当前 family 加入训练集之前的检出率，橙线表示加入当前 family 并重新训练后的检出率，浅蓝区域表示该轮获得的恢复增益。

该顺序实验揭示了三点。第一，TF-IDF 一旦见过当前 family，after recall 基本达到

1.00，说明 F1–F5 在词项和短语层面仍保留明显批次特征。换言之，文本 family 的静态可检性很强，只要同批样本进入训练集，稀疏词项模型就能迅速抓住同源生成痕迹。第二，BGE 的 before recall 更稳定，F1、F3、F4、F5 在未加入当前 family 前已经达到较高召回，但 F2 显著跌到接近 0。这与 F2 的检测反馈修正机制一致，它更有效地削弱了原有表层特征，并把文本推离前序 family 的已见分布。第三，F5 更换为 Gemini 后，两个检测器的 before recall 都出现下降，尤其 TF-IDF 从 F4 的高检出跌到 F5 的 0.60，说明底层生成模型会留下服务商和模型相关的深层表达指纹；这种指纹既体现在用词习惯中，也体现在更高层的表达节奏和句式组织中。

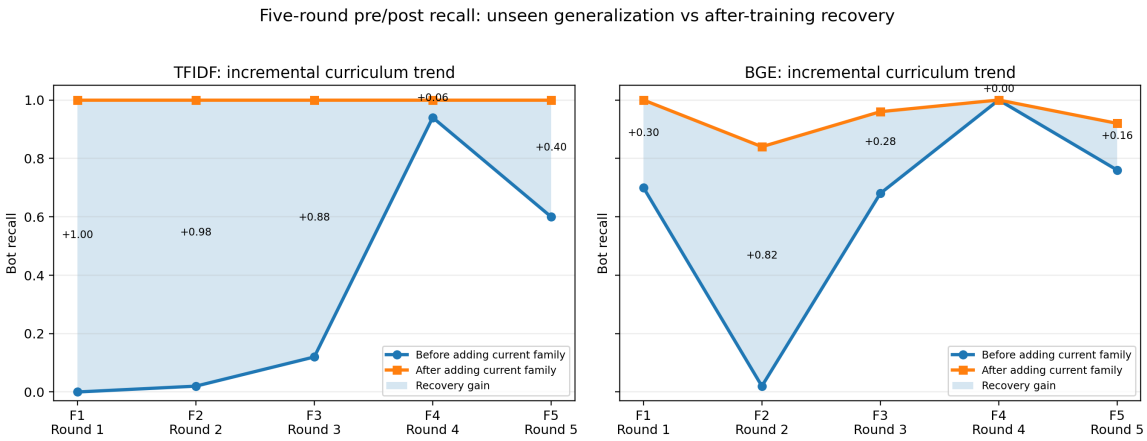


图 9: 文本增量课程中的顺序效应。横轴表示本轮加入训练集的 family，纵轴表示 bot recall；蓝线为加入当前 family 前的未见检出率，橙线为加入当前 family 并重新训练后的检出率，浅蓝区域为恢复增益。结果显示，TF-IDF 对已见 family 的同批次检出恢复极快，BGE 的未见检出整体更稳定，但 F2 的检测反馈修正和 F5 的 Gemini 服务商切换都会造成明显分布位移。

这一结果给检测流程带来一个实用启示。BGE 更适合承担未见 family 的高召回发现，因为它对多轮文本变体的 before recall 更稳定；TF-IDF 更适合在少量同批样本被确认后快速扩展检出范围，因为它能高效捕捉同源生成批次的词项和短语痕迹。因此，更现实的文本治理流程可以采用“BGE 发现候选簇、人工确认少量账号、TF-IDF 快速追踪同批次账号”的组合策略。这样的流程也解释了为什么单一静态分数不足以评价检测器，恢复速度本身就是泛化能力的一部分。探究文本检测有效性的归因见附录 E。

5.4 图泛化性 baseline

图实验使用一个单独的共享环境运行，包含 150 个生成机器人、258 个生成帖子、790 条生成评论、3,057 个用户节点和 54,067 条用户-用户边。该实验只使用图结构特征，不读取评论文本。它回答的问题与文本实验互补：如果机器人拥有浏览、发帖、二级回复、通知和回访机制，图检测器能否跨图行为家族泛化；当新家族出现后，少量标签能否让模型恢复。

5.4.1 图数据集特性分析

图 10 给出 GraphStats LR 的增量恢复结果。第一步面对任意一个未见 G 家族时，blind recall 都接近 0，说明原始 BotSim 图边界无法直接迁移到新的共享环境图分布。第二步和第三步迅速上升到 0.8–1.0，说明 G1–G3 之间确实存在可迁移的结构信号。不过，这种差异还不足以充分拉开图检测算法之间的性能差距。只要检测器见过任意一个新图家族，多数方法都能恢复到较高召回，G1–G3 更像同一代共享环境机制下的不同参数化行为分布。

G4 的设计结构是把机器人放到过去人类发帖和评论节点附近，让它们依据既有讨论位置决定发帖、回复、回访和互动对象，从而主动构造出边与入边行为。与 G1–G3 相比，G4 机器人更常被回复，也更多地与 human 发生交错互动。G4 的加入让检测结果差异显著增大。图 10 中，即使模型已经见过 G1–G3，面对 G4 时 GraphStats LR 的 blind recall 仍回落到 0。这个结果说明，图网络侧仍存在边关系指纹；一旦 bot 的入边、出边和人机互动方式发生结构性变化，已学到的图边界会再次失效。

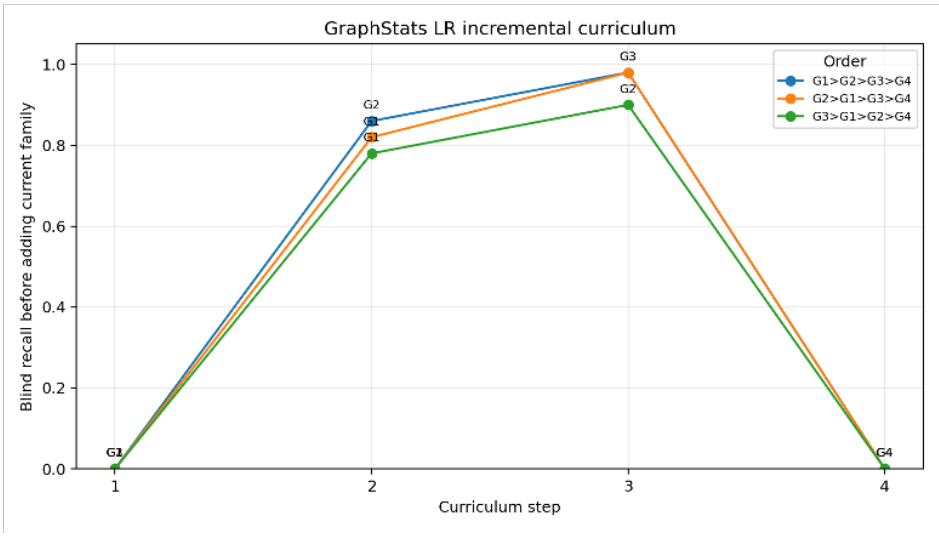


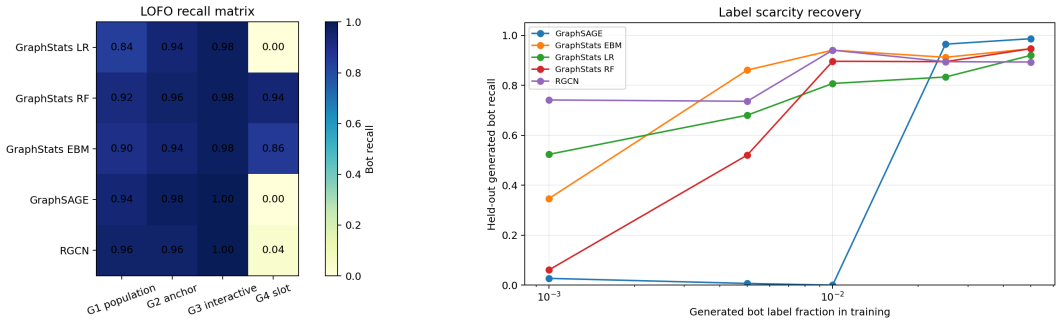
图 10: 图行为家族的增量泛化与 G4 压力测试。横轴为 family 进入训练集的顺序，纵轴为加入当前 family 前的 blind recall；G1–G3 在见过其他共享环境家族后恢复很快，但 G4 再次造成明显分布位移。

5.4.2 图检测算法特性分析

图 11a 体现出不同图检测算法之间的显著差异。理解这一结果，需要先区分各类模型的表达能力。GraphStats LR 在显式图统计特征上学习线性边界，优点是简单、稳定、可解释，但它只能表达单调的线性组合关系。GraphStats RF 通过树结构进行非线性划分，可以学习特征阈值、局部规则以及多个图统计特征之间的组合模式。GraphStats EBM 也使用显式图统计特征，但通过 boosting 学习可解释的非线性效应和部分交互关

系。GraphSAGE 和 RGCN 则进一步从图邻域中学习节点表示，表达自由度更高，能够利用邻居组成、边类型和消息传递模式，但它们也更依赖足够的新家族标签来稳定学习新的局部结构。

这一差异直接解释了 G4 上的结果。GraphStats LR 对 G4 的召回为 0，说明线性图统计边界无法处理 G4 带来的组合位移。G4 让机器人获得入边、回访和更多 human 互动后，许多单变量特征都变得更接近人类，线性模型很难表达“单项看似正常、组合上仍然异常”的结构。GraphStats RF 和 GraphStats EBM 在 G4 上仍保持较高召回，说明非线性阈值、特征交互和局部规则可能能够捕捉这种组合图指纹。SAGE 自由度更高，按理说拟合能力更强，但是在 G1-4 留出家族中测试表现不佳，可能因为数据样本量不足，无法支撑 SAGE 走向稳定收敛。这也体现在图 11b 中，它在低标签阶段几乎没有恢复，但当标签达到某个阈值后突然跃升，并在高标签区成为表现最强的方法。这说明归纳式图神经网络需要足够多的新家族标签来稳定学习邻域聚合模式；一旦样本量跨过阈值，它可以从纯图结构中获得很强的表达能力。



(a) G1–G4 留出家族召回矩阵。 (b) 图结构标签稀缺恢复。

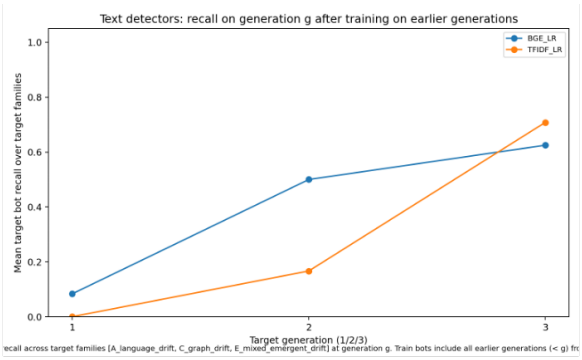
图 11: 图检测算法的差异与恢复。左图显示，不同图检测器对 G4 的反应差异很大，RF 和 EBM 仍能检出较多 G4 机器人，而 LR、GraphSAGE 和 RGCN 在该列上接近失效。右图横轴为加入训练的生成机器人标签比例，纵轴为留出生成机器人召回率；显式图统计模型在少量标签下逐步恢复，GraphSAGE 在标签达到阈值后快速跃升并取得最高召回。

因此，图结构检测给出的部署启示更加偏向“少量新标签驱动的快速恢复”。当平台只能标注极少数新 bot 时，可解释图统计模型更稳，因为它们能用入边、出边、互惠、回复类型和边方向等低维特征快速形成规则。当平台能够积累更多新家族标签，并且图拓扑稳定、关系类型可靠时，GraphSAGE 这类纯图结构模型更值得使用。大数据量下推荐优先考虑纯图结构或图神经网络方法；低标签和早期预警阶段，则应以 GraphStats RF/EBM 这类非线性但可解释的结构模型作为主力。

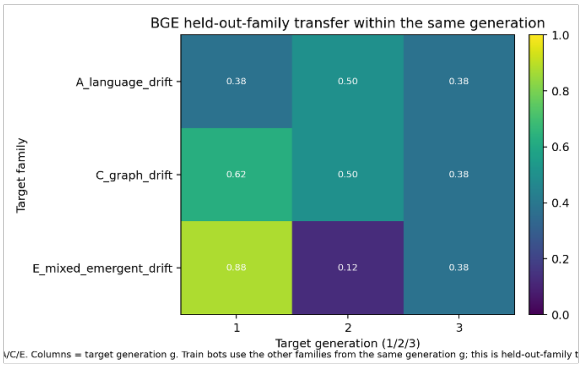
5.5 动态测试结果

前面的静态 family 测试可以看成动态测试的一个特例。它固定若干生成机制，再用 LOFO、顺序加入和标签稀缺协议观察检测器能否跨分布迁移。动态测试把这一过程自动化。系统先生成一代 A/C/E 机器人，记录检测与审计反馈，再自动调整下一代的 persona、语言提示、行为参数和图互动策略，形成连续漂移的目标分布。这样，评估对象从一组固定 family 扩展为一条会随反馈持续移动的生成轨迹。

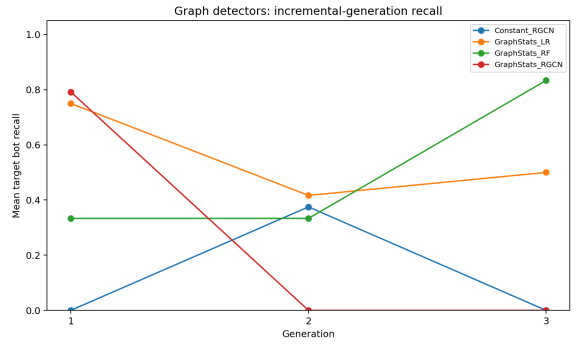
图 12 汇总三代动态测试结果。图 12a 显示文本检测器在增量代际协议中的恢复曲线。训练集包含更早代机器人，测试目标是当前代 A/C/E 家族的平均召回。BGE 起点高于 TF-IDF，说明稠密语义表示在初见漂移家族时仍有一定迁移能力；TF-IDF 前两代恢复较慢，但到第 3 代达到 0.708，超过 BGE 的 0.625。这与静态文本实验的结论一致。BGE 更稳，TF-IDF 一旦积累到足够相近的同源样本，能够迅速抓住批次词项和短语痕迹。



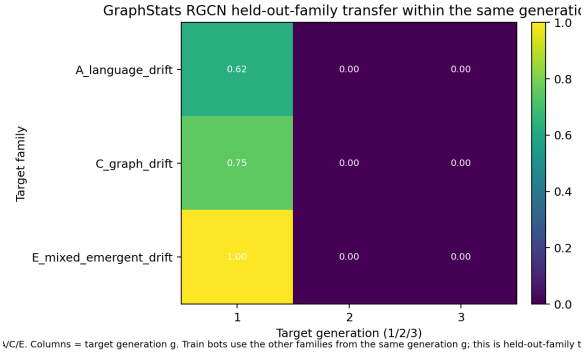
(a) 文本检测器的增量代际恢复。



(b) BGE 的同代留出家族迁移。



(c) 图检测器的增量代际恢复。



(d) 图检测器的同代留出家族迁移。

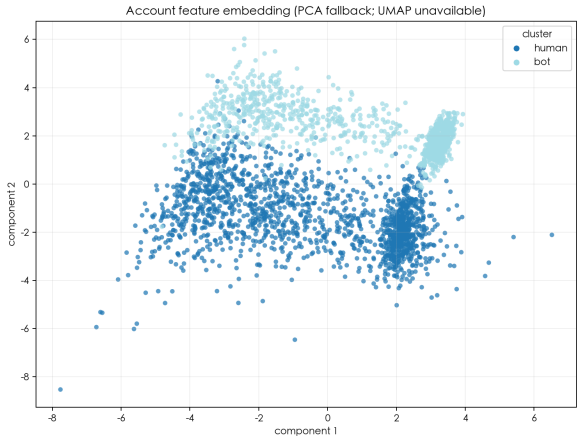
图 12: A/C/E 连续漂移动态测试结果。上排展示文本侧结果，下排展示图侧结果；左列为训练早期代后测试当前代的增量代际恢复，右列为同一代内留出目标 family 的迁移矩阵。四张图共同说明，自动化连续漂移复现了静态 family 测试中的主要模式，同时进一步暴露了代际变化和漂移轴变化对不同检测器的影响。

图 12b 展示 BGE 的同代留出家族迁移。结果体现不同 generation 和不同漂移轴之间的难度并不单调。某些 family 在第一代较容易迁移，后续代反而变难，说明检测难度

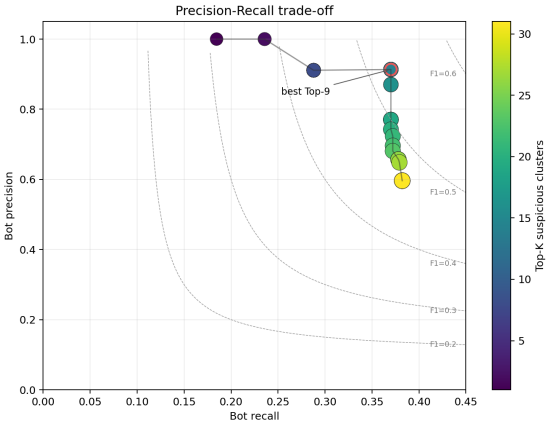
取决于训练中可见的同代 family 是否覆盖目标 family 的语言和行为方向。该现象与静态 LOFO 矩阵相同，平均召回需要和逐 family 迁移矩阵一起解读。

图侧结果更不稳定。图 12c–d 显示，GraphStats RF 到第 3 代明显恢复，而 RGCN 变体在后两代接近崩溃；同代图迁移也从第 1 代的较高召回转为后续代的大面积失效。这个结果呼应 5.4 的图 family 实验。图检测器对生成环境和互动机制非常敏感，一旦机器人进入讨论、收到回复、回访和连接人类节点的方式发生改变，早期图边界很容易失效。

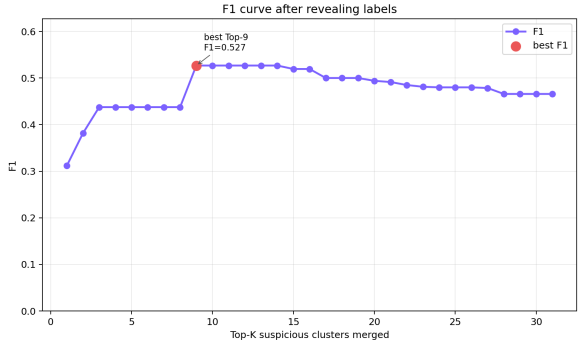
总体来看，自动化动态测试与前面的静态测试给出一致结论。文本侧表现为 BGE 初始迁移更稳、TF-IDF 随同源样本积累快速恢复；图侧表现为少量已见分布可以带来恢复，但图结构漂移会让不同算法出现更剧烈分化。动态测试的增量价值在于，它把“构造一个新 family 再测试”的人工流程转化为连续过程，从而观察检测器在多轮分布扩展中的恢复、饱和和崩溃。由于当前动态实验规模小于静态实验，我们将其作为协议演示和趋势证据，逐单元格数值放入附录 H。



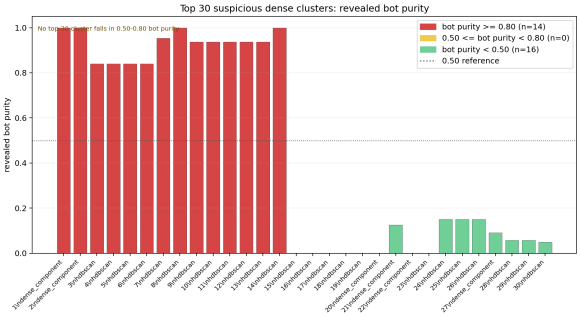
(a) 账号嵌入空间中的 HDBSCAN 聚类。



(b) 候选簇的 precision–recall 权衡。



(c) 阈值或 top-k 变化下的召回。



(d) 揭示标签后的高密度簇机器人纯度。

图 13: 无监督机制簇发现结果。HDBSCAN 在发现阶段不读取人机标签，标签只用于事后计算纯度、精确率和召回率。结果显示，抽象行为空间中确实存在高纯度机器人簇，但整体召回有限，因而更适合作为人工审核和少样本增量训练的候选发现器。

5.6 无监督高密度簇检测方式的探索

前面的实验都默认存在一定数量的人机标签，可以训练或更新检测器。然而真实平台经常首先面对无标签场景。一个新机器人机制刚出现时，平台往往不知道哪些账号属于同一批次，也没有足够标注样本支持监督训练。因此，无监督发现能否先圈出一批高可疑账号，是平台治理中很自然的一步。

我们的出发点来自本文的分布视角。社交机器人并没有固定不变的单一特征，但同一生成机制会让账号在抽象行为空间中形成异常集中的局部区域。于是，一个可行思路是先把账号映射到高维行为表示，再寻找高密度账户簇。如果这些簇在事后揭示标签时呈现较高机器人纯度，就说明无监督方法确实捕捉到了机制生成留下的密度结构。

我们使用 TF-IDF 账号表示、HDBSCAN 与 dense component scan，在发现阶段不读取人机标签。标签只在最后用于评估聚类结果。图 13a 显示，账号嵌入空间中确实存在若干相对紧密的簇；图 13d 进一步表明，揭示标签后，一部分高密度簇几乎全部由机器人构成，另一部分则主要由人类构成。这说明机器人按照 Family 种类集中聚集的密度结构的存在。不过，图 13b–c 也显示该方法存在明显精确率—召回率权衡，最佳 Top-9 F1 约为 0.527，召回约为 0.35–0.40。换言之，它能找到一批很可疑的机制簇，但会漏掉大量分散机器人，不能直接作为二分类检测器使用。

因此，本实验启示，无监督或自监督发现具备候选挖掘价值，但当前效果仍然有限。真实平台可以把这类方法放在检测链路前端，用来标记高可疑账号簇，再交给人工审核或小样本标注。随后，这些种子标签可以进入前文讨论的增量恢复流程，帮助监督检测器快速适应新分布。

附录 I 给出该探索的发现流程、输出含义和使用边界。

6 讨论

6.1 动态生成架构的意义

本文的静态 family 测试和动态漂移测试给出了相近的总体结论。检测器在见过相似生成机制后恢复很快，面对未见家族或新一代漂移时表现会明显分化。这可能让人产生一个疑问：如果静态泛化测试已经能暴露问题，为什么还要构建动态数据集？

答案在于，动态数据集提供的是一个持续生成测试分布的框架。只要生成框架成立，我们就可以继续制造新的语言、行为和图结构组合，而无需每次重新手工设计一整个数据集。这种可持续性来自动作和响应的解耦。动作层决定机器人浏览什么、是否发

帖、是否回访以及如何处理通知；响应层决定具体说什么、用什么语气表达、如何组织文本。解耦之后，研究者可以在不破坏整体环境的情况下单独更新 persona、动作策略或文本生成策略，持续产生新的机器人测试数据。由此，动态数据集在面对更新更强检测器的同时，总能制造新的差异构建更难的数据集。

6.2 机器人与人行为存在本质区别是伪命题

本文结果提醒我们，存在一个能永久抓住“机器人本质”的通用检测算法的假设并不成立。LLM 社交机器人不是一个稳定自然类，它们更接近由模型、prompt、persona 和互动反馈共同塑造出来的行为分布。检测器在某个数据集上表现很好，往往说明它学到了该数据集中已出现生成机制的边界；当生成机制扩展到新的语言风格、互动结构或时间过程时，原边界就可能失效。

因此，泛化失败的关键原因并不只是模型不够强。更深层的问题是，训练数据提供的机器人分布过窄，算法容易把模板伪影、零入边或异常互惠率当作稳定判据。强模型可以学到更复杂的相关性，但如果训练分布没有覆盖新的行为路径，它仍然可能在 held-out family 或连续漂移中失效。

更合理的目标是寻找人类与机器人在综合行为上的分布差异，并持续监控这些差异如何移动。这个综合行为空间应同时包含文本、动作、图结构、时间节律、群体协同和跨社区扩散。理想检测系统不应只输出单账号风险分数，还应找出哪些账号形成异常高密机制簇，哪些结构特征驱动检测，少量新标签能否让模型恢复，以及当前边界对下一轮生成策略是否仍然有效。

6.3 检测算法报告应包含泛化矩阵和恢复曲线

对于研究论文和平台内部评估，单个随机切分准确率已经不足以描述检测能力。我们建议至少报告 family transfer matrix、recovery curve 和 artifact audit 三类结果。第一，family transfer matrix 显示检测器从已知家族迁移到未知家族时的衰减。第二，recovery curve 显示随着新标签到达，检测器需要多少监督才能恢复。第三，artifact audit 说明检测器是否依赖明显生成伪影，例如单向回复、零入边、异常互惠率或服务商语言指纹。

这些报告项还能帮助解释不同算法的角色。文本检测器适合快速发现语言模板和服务商指纹，图统计检测器适合在少量新标签下快速恢复，图神经网络适合在拓扑稳定、关系类型可靠、节点特征充分的条件下提供更强表示。若平台只看一个总分，就容易忽略初次遇到新分布时是否能检出和标注少量样本后能否恢复这两个治理问题。

6.4 人机协同的在线社区机器人治理工作流畅想

我们的结果支持一种人机协同发现机器人的工作流。第一步，平台使用无监督密度或异常簇方法发现疑似新机制分布。我们的 HDBSCAN 与 dense component scan 结果不能作为最终分类器，但能以 Top-9 F1 约 0.527 的水平圈出一批高相似候选簇，适合作为人工审核入口。第二步，人类审核员对候选簇做小样本定性标注，判断其是否体现协同操纵、虚假共识或异常自动化。第三步，少量新标签进入增量训练，帮助检测器恢复。

图标签稀缺实验展示了这一工作流的可行性。GraphStats LR 在 10% 生成标签下达到 0.807 召回率，在 50% 下达到 0.920。它说明平台不必等待完整标注数据集才能适应新家族。更实际的目标是构建快速恢复机制，发现新分布、确认少量样本、更新检测器，再继续监控下一轮分布漂移。

7 局限与展望

回顾全程，本文的实验仍然建立在离线沙盒之上。离线环境使我们能够精确控制并完整记录生成与检测过程；但它仍然缺少真实社交平台中的一部分随机噪声和制度约束，例如真实平台的反作弊限流、推荐系统重排，以及用户侧不可预测反应。因此，本文结论更适合作为检测器泛化能力的受控压力测试，不能直接等同于真实平台部署效果。

第二，本文主要基于 Reddit 场景和 BotSim-24 采集的人类行为数据。Reddit 的帖子—评论—回复结构适合研究弱关系互动图，但不同平台的互动机制、推荐逻辑、语言风格和治理规则差异很大。未来工作应将 FamilyBotBench 扩展到更多平台和数据集，比较同一检测器在不同社交生态中的泛化与恢复能力。

第三，本研究关注文本、动作和图结构，尚未系统纳入多模态内容。未来可以引入图像、视频和链接传播行为，并评估文本模型、图模型、多模态模型以及综合检测系统在连续分布漂移下的表现。

第四，当前 Agent 规模仍受到 API 调用成本和本地算力限制。本文的主要实验集中在百级到数百级机器人规模，能够揭示检测器在跨 family、少标签恢复和动态漂移中的差异，但距离真实平台中的大规模协同操纵仍有距离。后续可以通过更高效的本地模型、批量生成缓存和分布式运行扩大模拟规模，从而研究更复杂的群体协同、跨社区扩散和长期时间演化。

最后，本文也发现模型自身特性对泛化性检测有着显著影响，靠 prompt 调整带来的分布漂移总是有限，未来或许可以尝试通过对开源模型进行不同方向的微调继续实

验，实现更大尺度的行为漂移。

8 结论

社交机器人检测基准不应只评估静态准确率。随着 LLM 驱动账号越来越容易变化，关键问题是检测器是否能迁移到新的语言、行为、图结构和漂移家族，以及在少量新标签到达时恢复得多快。FamilyBotBench 通过受控机器人家族、共享环境图生成和连续漂移协议，将这一问题操作化。我们的实验表明，静态表现相似的检测器可能具有非常不同的泛化和恢复行为。对于研究者和平台治理团队，基于家族的评估提供了一种更有信息量的检测器审计方式，同时判断它们能否检测昨天的机器人，以及当生成过程改变时它们是否仍然有用。

参考文献

[1] Shangbin Feng, Herun Wan, Ningnan Wang, Jundong Li, and Minnan Luo. Satar: A self-supervised approach to twitter account representation learning and its application in bot detection. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management*, pages 3808–3817, Virtual Event, Queensland, Australia, 2021. ACM. doi: 10.1145/3459637.3481949.

[2] Shangbin Feng, Zhaoxuan Tan, Herun Wan, Ningnan Wang, Zilong Chen, Binchi Zhang, Qinghua Zheng, Wenqian Zhang, Zhenyu Lei, Shujie Yang, Xinshun Feng, Qingyue Zhang, Hongrui Wang, Yuhan Liu, Yuyang Bai, Heng Wang, Zijian Cai, Lijing Zheng, Zihan Ma, Jundong Li, and Minnan Luo. Twibot-22: Towards graph-based twitter bot detection. In *Advances in Neural Information Processing Systems*, volume 35, pages 35254–35269, New Orleans, LA, USA, 2022. Curran Associates, Inc.

[3] William L. Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems*, volume 30, pages 1024–1034, Long Beach, CA, USA, 2017. Curran Associates, Inc.

[4] Chris Hays, Zachary Schutzman, Manish Raghavan, Erin Walk, and Philipp Zimmer. Simplistic collection and labeling practices limit the utility of benchmark datasets for twitter bot detection. In *Proceedings of the ACM Web Conference 2023*, pages 3660–3669, Austin, TX, USA, 2023. ACM. doi: 10.1145/3543507.3583214.

[5] Buyun He, Yingguang Yang, Qi Wu, Hao Liu, Renyu Yang, Hao Peng, Xiang Wang, Yong

Liao, and Pengyuan Zhou. Dynamicity-aware social bot detection with dynamic graph transformers. arXiv preprint arXiv:2404.15070, 2024.

[6] Zhengyu Hu, Zheyuan Xiao, Max Xiong, Yuxuan Lei, Tianfu Wang, Jianxun Lian, Kaize Ding, Ziang Xiao, Nicholas Jing Yuan, and Xing Xie. Population-aligned persona generation for llm-based social simulation. arXiv preprint arXiv:2509.10127, 2025.

[7] Harsha Nori, Samuel Jenkins, Paul Koch, and Rich Caruana. Interpretml: A unified framework for machine learning interpretability. arXiv preprint arXiv:1909.09223, 2019.

[8] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, pages 2:1–2:22, San Francisco, CA, USA, 2023. ACM. doi: 10.1145/3586183.3606763.

[9] Jinghua Piao, Yuwei Yan, Jun Zhang, Nian Li, Junbo Yan, Xiaochong Lan, Zhihong Lu, Zhiheng Zheng, Jing Yi Wang, Di Zhou, Chen Gao, Fengli Xu, Fang Zhang, Ke Rong, Jun Su, and Yong Li. Agentsociety: Large-scale simulation of llm-driven generative agents advances understanding of human behaviors and society. arXiv preprint arXiv:2502.08691, 2025.

[10] Boyu Qiao, Kun Li, Wei Zhou, Shilong Li, Qianqian Lu, and Songlin Hu. Botsim: Llm-powered malicious social botnet simulation. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39(13):14377–14385, 2025. doi: 10.1609/aaai.v39i13.33575.

[11] Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, and Max Welling. Modeling relational data with graph convolutional networks. In *European Semantic Web Conference*, volume 10843 of *Lecture Notes in Computer Science*, pages 593–607, Heraklion, Crete, Greece, 2018. Springer. doi: 10.1007/978-3-319-93417-4_38.

[12] Ryosuke Takata, Atsushi Masumori, and Takashi Ikegami. Spontaneous emergence of agent individuality through social interactions in llm-based communities. *Entropy*, 26 (12):1092, 2024.

[13] Siyuan Wang, Zhuohan Long, Zhihao Fan, Xuanjing Huang, and Zhongyu Wei. Benchmark self-evolving: A multi-agent framework for dynamic llm evaluation. In *Proceedings of the 31st International Conference on Computational Linguistics*, pages 3310–3328, Abu Dhabi, United Arab Emirates, 2025. Association for Computational Linguistics.

[14] Yunzhe Wang, Gale M. Lucas, Burcin Becerik-Gerber, and Volkan Ustun. Implicit behavioral alignment of language agents in high-stakes crowd simulations. arXiv preprint arXiv:2509.16457, 2025.

[15] Shitao Xiao, Zheng Liu, Peitian Zhang, Niklas Muennighoff, Defu Lian, and Jian-Yun Nie. C-pack: Packed resources for general chinese embeddings. arXiv preprint arXiv:2309.07597, 2023.

[16] Ziyi Yang, Zaibin Zhang, Zirui Zheng, Yuxian Jiang, Ziyue Gan, Zhiyu Wang, Zijian Ling, Jinsong Chen, Martz Ma, Bowen Dong, Prateek Gupta, Shuyue Hu, Zhenfei Yin, Guohao Li, Xu Jia, Lijun Wang, Bernard Ghanem, Huchuan Lu, Chaochao Lu, Wanli Ouyang, Yu Qiao, Philip Torr, and Jing Shao. Oasis: Open agent social interaction simulations with one million agents. arXiv preprint arXiv:2411.11581, 2024.

附录

A 伦理与防滥用

本文研究社交机器人检测，因此具有双重用途风险。我们采取了几项保护措施。第一，所有机器人都在离线沙盒中生成和评估；没有任何生成账号被部署到真实平台。第二，LLM 只在调度器选择动作后生成文本；它不能自主优化平台行为。第三，动态漂移机制受到人类对齐审计约束，本文将其定位为检测压力测试，并避免将其设计成纯粹逃避检测的过程。第四，我们强调检测器评估协议和伪影分析，并避免发布绕过特定真实平台检测器的说明。

B AI 使用说明

本课题在实验代码构建、数据分析与可视化过程中使用了 Codex 作为辅助工具，并在论文排版阶段使用 Codex 辅助检查 LaTeX 结构、图表引用和编译问题。

开题汇报、期中汇报、期末汇报和期末论文正文的研究思路、论证结构与正文表述由自己完成，未使用 AI 代写。附录中的部分数据表、实验记录和图表说明使用 Codex 辅助整理，最后我都进行了核对、筛选和修改。

C 家族与检测器的详细规格

C.1 F1–F5 与 G1–G4 的操作化定义

正文表 1 给出家族概览。表 4 进一步说明每个家族在生成阶段实际改变了什么，以及它对应的研究问题。F1–F5 共享静态文本实验的基本任务和输出形式，差异来自语言控制路径；G1–G4 共享同一个离线社交环境，差异来自行为校准、上下文互动、通知回访和记忆机制。这样的设置使 family shift 具有可解释来源，同时避免把底层模型服务商直接等同于家族标签。

C.2 BGE 行为分布投影图的构造

正文图 3 是真实实验数据的二维可视化，而非手工生成的概念散点。我们以账号为单位构造文本表示，将同一账号在对应实验中的评论拼接为一个文档，删除空文本账号，然后使用 BAAI/bge-small-en-v1.5 编码为 384 维嵌入。静态文本部分包含 1,730 个有非空文本的人类账号、1,000 个原始 BotSim 机器人账号和 250 个 F1–F5 静态语言/人格家族账号；连续漂移部分包含 72 个 A/C/E 谱系账号。随后，我们对所有 BGE 向量做 L_2 归一化，并在合并后的嵌入矩阵上拟合 PCA，将前两个主成分用于可视化。图中横轴和纵轴分别解释约 10.0% 与 6.6% 的方差。

表 4: 机器人家族的详细生成机制。语言家族主要改变文本生成路径，图家族主要改变社会行为形成路径。

家族	核心机制	具体操作化	实验作用
F1	原始 BotSim 风格	使用偏正式、宏观、解释性的政治议题评论方式，保留原始系统常见的抽象总结倾向。	作为静态语言基线，测量检测器对原始模板伪影的利用程度。
F2	TF-IDF 表层修正	减少已知高风险抽象词和重复短语，鼓励更短、更具体、更口语化的表达；任务语境保持一致。	检验表层词汇修正能否形成足够大的 family shift。
F3	人类锚点局部对齐	每个机器人绑定少量人类锚点，参考锚点群体的聚合语言习惯，再执行局部 TF-IDF 修正；不复制具体人类文本。	检验向人类语义与风格分布靠近后，检测器是否仍能迁移。
F4	高维人格间接控制	以冲动性、情绪强度、争论倾向、生活经验、立场强度和表达长度等高维特质控制回答。	检验 persona 多样性是否削弱单一提示模板造成的语言集中。
F5	服务商与人格联合变化	沿用 F4 的高维人格机制，同时更换生成服务商与模型来源。	检验跨服务商、跨模型的语言分布迁移。
G1	人口统计式行为对齐	从人类聚合分布采样发帖、一级评论、二级回复、回访、跳过和通知反应倾向。	检验群体统计对齐形成的图结构能否被原始图检测器识别。
G2	人类锚点行为对齐	每个机器人参考少量人类锚点的局部互动习惯，包括活跃度、回复深度、外向互动和回访偏好。	检验局部行为模仿与总体统计模仿之间的结构迁移。
G3	上下文互动生成	机器人在共享环境中浏览帖子与评论串，维护记忆，并依据既往参与状态发帖、一级评论或二级回复。	检验由多轮环境反馈形成的交错图结构，以及更自然的入边、互惠与多层回复。
G4	通知回访强化	回退时间，在人类活动节点上插入社交机器人；在 G3 的共享环境基础上提高通知反应、回访概率和弱互动链形成机会；本文主实验将 G3/G4 合并为共享环境图口径。	检验被回复后回访、弱互惠和跨机器人互动是否能改变图检测信号。

图中每个点对应一个账号级文档，颜色表示数据来源或生成家族类型，椭圆表示各组在二维投影中的经验协方差轮廓。该图只用于展示 BGE 文本空间中的分布位置和分布展宽，不作为正式检测器结果；正式文本检测仍使用 TF-IDF+LR 和 BGE+LR 的训练/测试协议，相关数值见正文实验部分。

C.3 检测器的输入、结构与适用边界

表 5 统一比较本文使用的七种检测器。GraphStats 系列把用户局部互动压缩为显式特征，GraphSAGE 与 RGCN 直接在邻域上传播信息；TF-IDF 和 BGE 都使用账号级文本，但前者依赖稀疏词项，后者依赖稠密语义表示。它们在标签稀缺曲线上的差异，来自表示方式、函数复杂度、监督传播范围和训练时可见信息的共同影响。

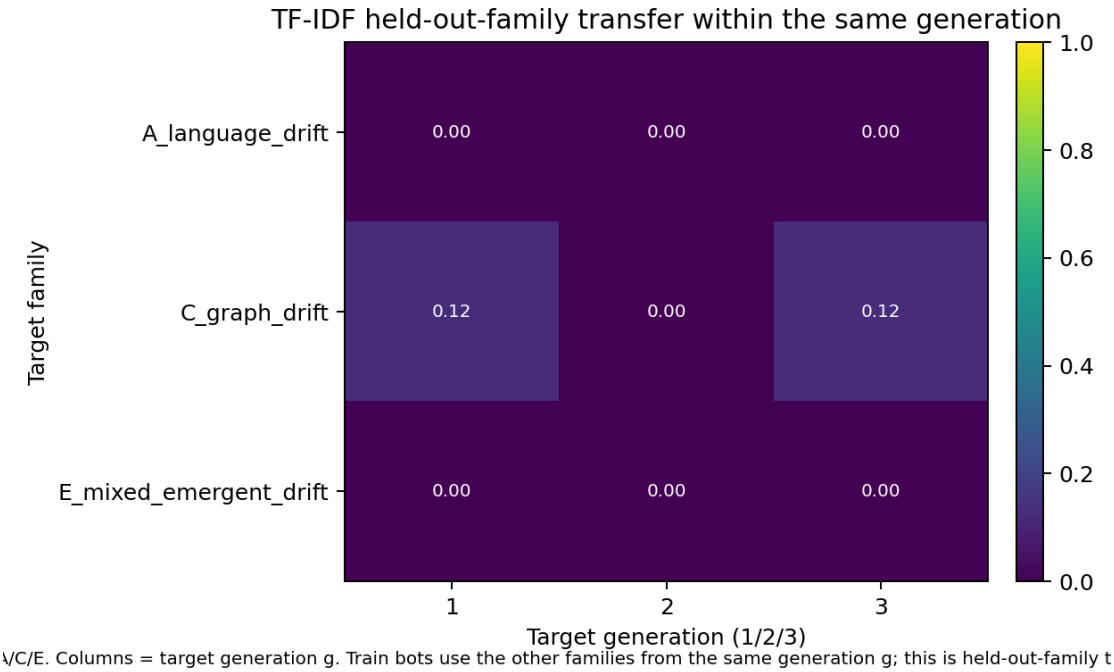
D 针对 TF-IDF 的攻击结果

图 14 记录了连续漂移实验中一个针对 TF-IDF 检测器的适配性攻击结果。由于本文在语言漂移中使用 TF-IDF 摘要作为轻量反馈器，每一轮漂移迭代都可以部分理解为机器人生成器在尝试降低 TF-IDF 检测器的可见特征。换言之，这个过程不再只是构造新分布，也具有对特定检测器进行规避的含义。

结果显示，在 3 条漂移谱系与 3 个代际组成的 9 次测试中，绝大多数 TF-IDF 检测召回为 0，其余也只有 0.12。这说明，当生成器持续接收某个检测器的反馈并据此调整语言分布时，针对该检测器的攻击非常有效。该实验的主要作用是方法警示：连续漂移基准不能直接把正式检测器的真实预测结果作为生成反馈，否则评估过程会退化为对该检测器的定向攻击，难以再解释为一般意义上的泛化测试。正文实验因此将正式检测器评估与生成反馈机制分开，并使用 held-out family 和 held-out detector 保持盲测。

表 5: 检测器原理、输入和解释边界。family、provider、model、temperature 和 user ID 只用于分组审计，不进入训练特征。

方法	输入	结构	主要优势	主要限制与解释边界
TF-IDF+LR	账号评论拼接后的词/短语稀疏向量	TF-IDF 向量器与逻辑回归	快速、可解释，可定位高权重 unigram/bigram。	容易学习词汇、主题、实体和模板短语捷径；跨主题或跨服务商迁移可能下降。
BGE+LR	账号文本的稠密语义嵌入	BGE 编码器与逻辑回归	能表示同义改写和较宽的语义相似性，对精确词汇重叠依赖较小。	嵌入维度难以直接解释，仍可能编码 family、provider 或主题偏差。
GraphStats LR	入/出度、边类型占比、权重、方向平衡、互惠、回复计数等用户级统计	标准化与逻辑回归	样本效率高、训练稳定、系数透明，适合归纳式部署代理。	只表达显式统计的线性组合，难以捕捉复杂阈值与高阶交互。
GraphStats RF	与 GraphStats LR 相同的显式图统计	随机森林	能学习阈值型和交互型结构，可作为 shortcut 上限检查。	极少标签下方差较大，特征贡献的方向性较难解释。
GraphStats EBM	与 GraphStats LR 相同的显式图统计	可解释提升机，包含单特征非线性函数与有限二阶交互	兼顾非线性、少样本恢复和全局解释。	仍依赖人工设计的图统计，无法自动学习未编码的邻域模式。
GraphSAGE	节点特征与同质化用户互动边	两层 SAGEConv 邻域聚合与节点分类头	可归纳到未见节点，能学习局部邻域表示。	本实验中关系类型被折叠；参数较多，少量标签下可能出现明显恢复阈值。
RGCN	节点特征与带类型关系边	两层 RGCNConv 关系特定消息传递与节点分类头	能区分评论帖子、回复评论和收到回复等关系语义。	观察式转导设置可能利用完整测试拓扑或关系捷径，部署解释需与归纳模型分开。



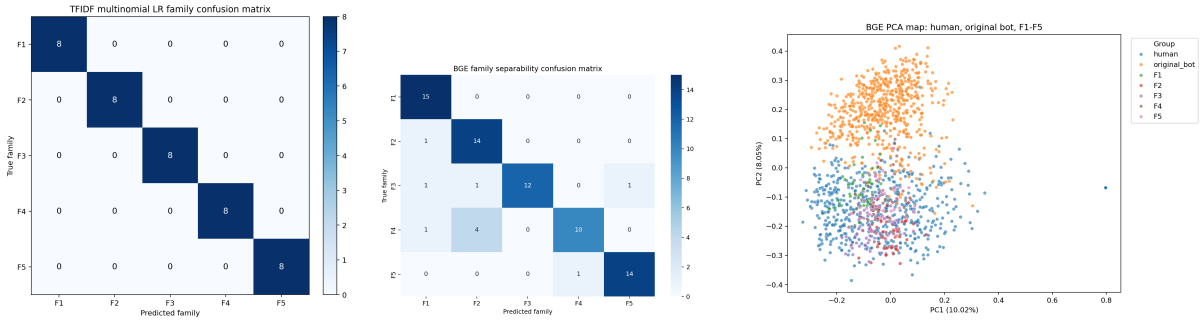
\/C/E. Columns = target generation g. Train bots use the other families from the same generation g; this is held-out-family t

图 14: 针对 TF-IDF 检测器的适配性攻击结果。图中 3 条漂移谱系与 3 个代际共形成 9 次测试，多数 TF-IDF 检测召回为 0，仅少数单元为 0.12，说明将检测器反馈直接用于连续漂移会产生强规避效果。

E 文本检测归因

E.1 家族指纹仍然可检测

我们接着考察生成语言家族本身是否可分。一个家族分类器使用 TF-IDF 可以以 1.000 准确率预测 F1–F5 成员关系，使用 BGE 的准确率为 0.950。图 15 中，TF-IDF 与 BGE 混淆矩阵都呈现强对角结构，BGE 降维散点也显示多个家族在语义空间形成不同密度区域。这对基准设计是一个警告。尽管这些家族被设计为以不同方式更接近人类，它们仍留下强烈的生成家族指纹。



(a) TF-IDF 家族分类混淆矩阵。 (b) BGE 家族分类混淆矩阵。 (c) BGE 嵌入在前两个主成分上的分布。

图 15: F1–F5 的家族可分性。前两幅图以真实 family 标签评估生成机制指纹，第三幅图仅作二维可视化。较强的可分性说明不同 persona、改写和服务商路径仍会形成稳定分布簇，因此检测器可能利用家族伪影，而未必获得跨家族通用的人机判别边界。

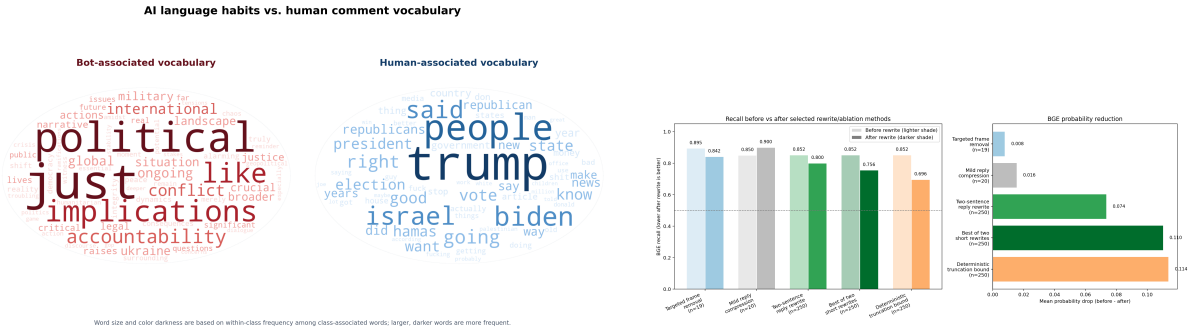
静态文本 OOD 实验整体处于中等水平。最强的平均 OOD 方法是 BGE kNN 距离（$k = 20$），平均 AUROC 为 0.648。在该设置中，监督式机器人概率作为 OOD 分数的稳定性不足。这些结果表明，OOD 检测可以帮助标记不熟悉的生成家族，但仍需要与显式留出家族评估配合使用。

附录 F 补充五类静态文本实验的正式定义、锚点相似度数值、BGE 表示消融、TF-IDF 删词统计和典型反事实案例。

E.2 伪影归因与话题控制

家族可分性提示我们继续追问检测器抓住的究竟是更稳定的表达习惯，还是少量高权重词项和主题差异。图 16 左侧比较原始机器人与人类评论的高频词。机器人侧更集中于 political、implications、accountability 等抽象议题词，人类侧则包含 said、people、trump 等更接近日常 Reddit 讨论的词项。右侧的五组改写消融表明，不同程度的局部语义改写、压缩和 detector-aware 修订确实会改变检测概率，但没有一种单次改写能够稳定消除全部家族信号。

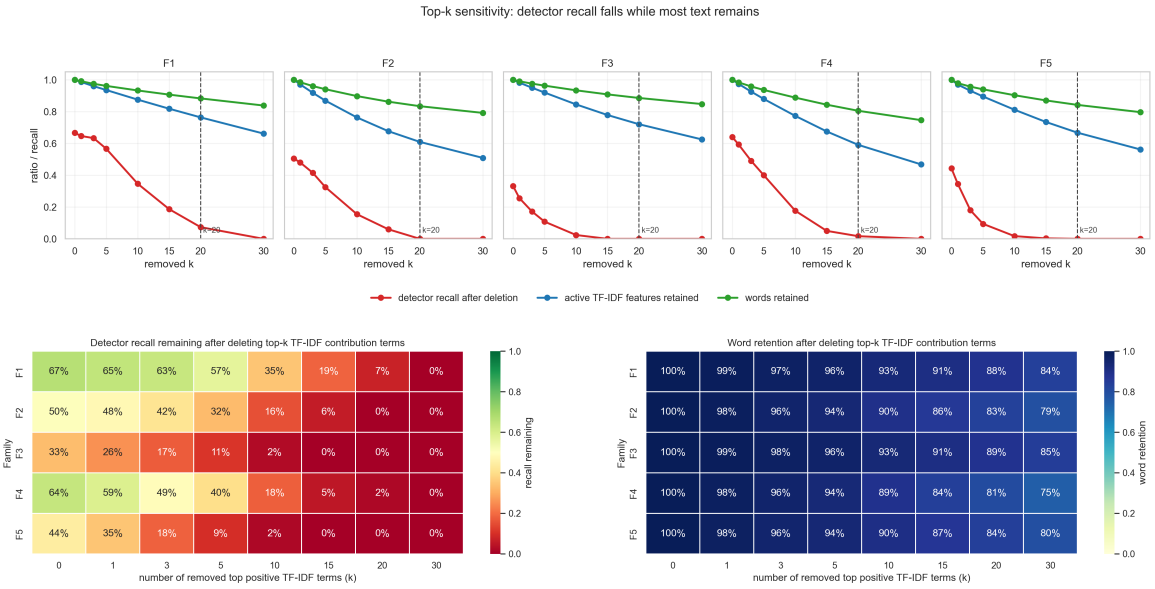
为了量化少量局部强特征的影响，我们依次删除每个机器人文档中对 TF-IDF 机器人方向贡献最大的 top-k 词项。图 17 显示，随着 k 增大，多个家族的机器人召回率快速下降；与此同时，文档仍保留了大部分词汇和相当数量的活跃 TF-IDF 特征。该结果



(a) 原始机器人与人类评论的高频词差异。 (b) 五类文本改写策略的消融结果。

图 16: 文本生成伪影的两个层面。词云揭示机器人与人类语料中的明显词汇偏置；改写消融说明局部语言修订可以削弱部分信号，但生成机制仍会从其他词项、句式或语义方向留下家族指纹。

说明静态高召回的一部分来源于少数高度集中的局部词项，删除这些词项后文本语义并未整体消失。



(a) 删除 top-k 正贡献词后的召回率。 (b) 相同设置下的词汇保留比例。

图 17: TF-IDF 局部强特征敏感性。上图展示不同 k 下检测召回率、机器人概率和文本保留统计的整体趋势；下方两幅热力图分别呈现各家族的召回剩余比例和词汇保留比例。少量高贡献词被删除后，检测性能下降速度明显快于文本信息损失速度。

话题控制实验提供了互补证据。图 18 将机器人和人类限制在匹配的帖子主题中重新评估 TF-IDF；各主题桶的召回率仍接近总体水平。由此可见，当前 TF-IDF 高分还来自话题之外的信号，词汇风格、短语组合与生成机制伪影仍在发挥作用。

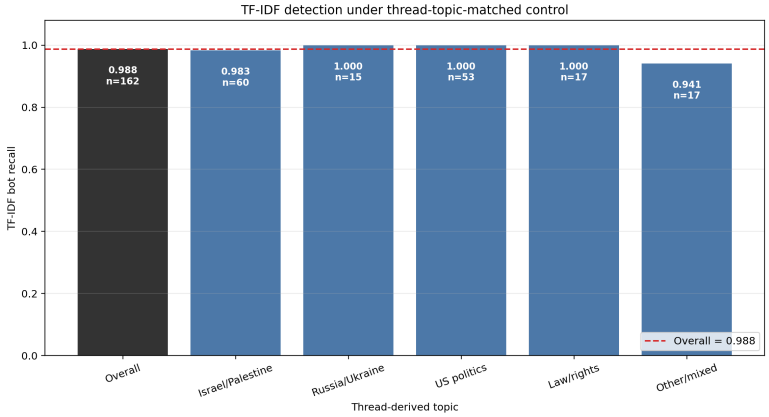


图 18: 帖子主题匹配控制下的 TF-IDF 检测召回率。横轴为匹配后的主题桶，柱上标注机器人召回率与样本数，虚线表示总体召回率。控制主题后性能仍保持较高，说明检测信号不能完全由话题词解释。

F 静态文本实验的补充审计

F.1 五类文本实验的角色

静态文本阶段包含五项互补实验。LOFO 测试跨生成机制迁移；语义簇控制在相近内容中比较人机语言；锚点相似度量化 family 与人类池的接近程度；家族可分性检验生成器是否留下机制指纹；静态 OOD 检验无监督距离能否识别未见 family。表 6 给出它们的输入与解释目标。

表 6: 静态文本五类实验的正式定义。五项实验回答不同问题，不能用单一分数互相替代。

实验	训练/比较方式	主要解释目标
Leave-One-Family-Out	原始人类、原始机器人和四个生成家族用于训练；第五个家族完整留出测试。	测量检测器对全新生成机制的监督式迁移。
语义簇/话题控制	在帖子主题或语义相近的桶内匹配机器人与人类文本，再运行检测器。	排除“机器人只是讨论不同主题”的简单解释。
Anchor Similarity	比较 family 到人类池的 BGE 最近邻余弦、风格标准化距离和原始 TF-IDF 机器人概率。	检验人类锚点对齐是否真的让 family 接近人类分布。
Family Separability	仅在 F1–F5 内训练 family 分类器，预测生成路径标签。	测量 persona、改写和服务商机制留下的 family 指纹强度。
Static Text OOD	用已知分布拟合距离或密度分数，再对留出 family 计算 AUROC。	测量无需该 family 标签时，能否把它识别为新分布。

F.2 人类锚点相似度

图 19 显示 F3 的设计目标得到了部分支持。F3 的 BGE 最近人类余弦最高（0.771），风格标准化 L_2 距离最低（2.710），原始 TF-IDF 检测器给出的平均机器人概率也最低（0.107）。这一结果说明人类锚点和局部 TF-IDF 修正共同推动 F3 向人类池靠近。F3 仍然能被 family 分类器识别，说明“更接近人类”与“完全消除生成机制指纹”是两个不同命

题。

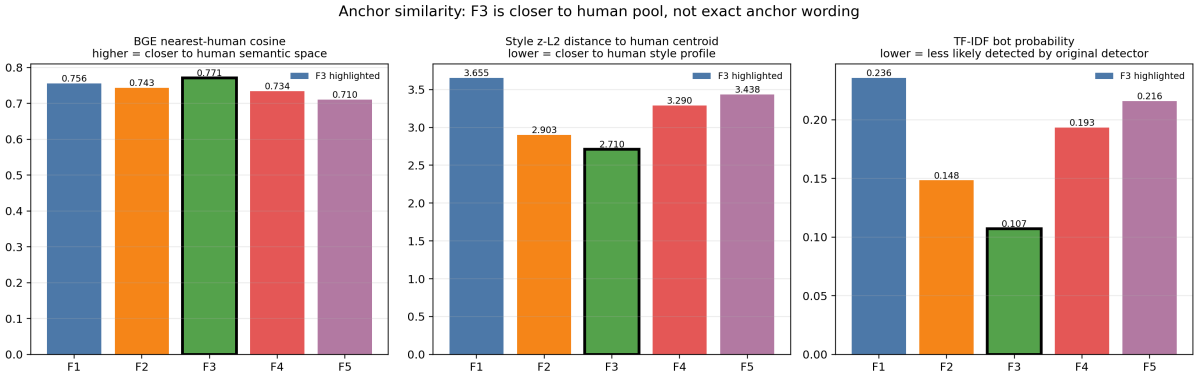


图 19: F1–F5 的人类锚点相似度。左图为 BGE 最近人类余弦，相似度越高表示语义空间越接近人类池；中图为风格特征到人类质心的标准化距离，越低越接近；右图为原始 TF-IDF 检测器的机器人概率，越低表示越难被原始模型识别。F3 在三项指标上均呈现最稳定的人类对齐信号。

F.3 词汇偏置与 family 可分性

图 16 的词云显示，原始机器人评论更集中于 political、implications、accountability、conflict 和 landscape 等抽象议题词，人类评论则包含 said、people、vote、going、know 等更接近日常讨论的词项。这个结果只用于定位可能的词汇偏置，不能单独证明某个词具有稳定的人机含义。

图 15 进一步显示，TF-IDF family 分类器以 1.000 准确率识别 F1–F5；BGE family 分类准确率为 0.950。BGE 混淆中，F1 与 F2 各有 15/15 个样本正确，F3 有 12/15 个正确，F4 有 10/15 个正确，F5 有 14/15 个正确。错误主要发生在相邻语言控制机制之间。静态文本 OOD 的最佳平均方法为 BGE k-近邻距离（$k = 20$），平均 AUROC 为 0.648。三个结果合在一起说明 family 指纹很强，但“能够区分已知 family”和“能够把未见 family 稳定识别为 OOD”仍是两个不同能力。

F.4 文本改写策略与证据边界

图 16 汇总了五种改写路线。表 7 补充其精确结果。局部语义改写与强压缩可以有限降低 BGE 检出率，轻量压缩反而提高检出率；detector-aware 选择下降更明显，但它读取检测反馈，只能作为对抗压力测试。确定性截断获得最大下降，同时损失上下文与自然度，因此不能被视为高质量人类模仿方案。

表 7: 五种文本改写策略的 BGE 机器人召回率。负变化表示检出率下降。

策略	改写前	改写后	变化
局部语义/权利框架改写	0.895	0.842	−0.053
轻量压缩/碎片化表达	0.850	0.900	+0.050
强压缩/两句表达	0.852	0.800	−0.052
Detector-aware 候选选择	0.852	0.756	−0.096
确定性前 40/80 词选择	0.852	0.696	−0.156

F.5 BGE 表示消融

BGE 嵌入为 384 维，线性检测头的 logit 可以写成截距与嵌入向量在分类权重方向上的投影之和。图 20 比较三种干预，分别是删除 family 分类最强的 50 个维度、删除单一机器人方向投影、将嵌入向人类质心收缩 25%。删除单一机器人方向后，大部分 family 的召回下降仍接近 0.8–1.0，说明 BGE 信号分散在多个维度；向人类质心收缩带来更大下降，说明全局几何位置比单一线性方向更关键。

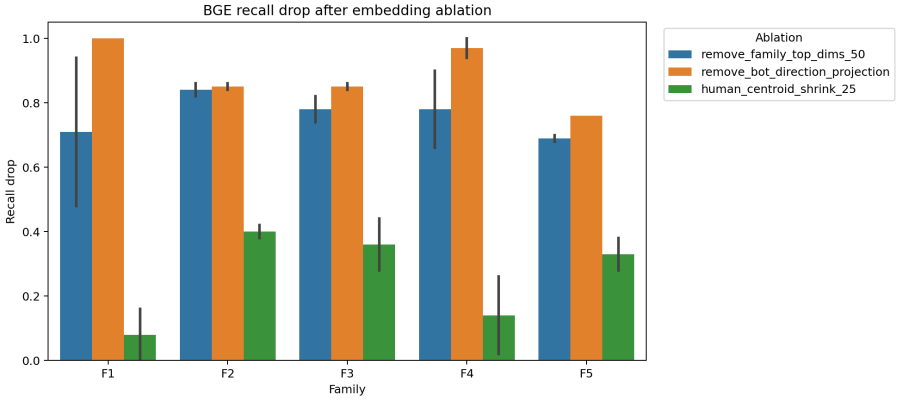
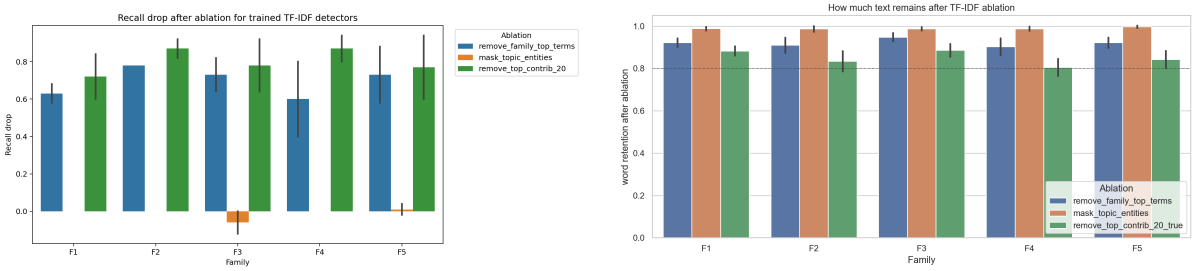


图 20: BGE 嵌入消融后的召回率下降。蓝色删除 family 分类贡献较大的 50 个维度，橙色删除单一机器人方向投影，绿色将样本向人类质心收缩 25%。绿色干预造成更明显的检测下降，支持 BGE 家族信号分布在多维几何结构中的判断。

F.6 TF-IDF 特征族消融与信息保留

图 21 同时报告检测下降和文本保留。删除 family 高频词或每个文档的 top-20 正贡献词，会显著降低召回；屏蔽主题实体几乎不改变检测，F3 上甚至出现轻微负下降。top-20 删除后，平均保留 85.0% 的原始词，活跃 TF-IDF 特征从 72.2 降至 50.6，仍保留 67.0%。平均请求删除 19.3 个词项，实际匹配 17.9 个，约占原活跃特征的 27.3%。这说明少量强贡献词项能够支撑大量检测置信度。



(a) 不同删词策略造成的召回下降。 (b) 执行相同消融后保留的文本比例。

图 21: TF-IDF 特征族消融。family 高频词和样本级 top-20 贡献词会显著影响检出率，同时文本仍保留约 80%–99% 的词；主题实体屏蔽的影响很小，进一步说明检测器依赖的信号超出了主题名称本身。

图 22 给出一个典型 F3 样本。删除 17 个匹配的 unigram/bigram 后，文本仍保留 85.6% 的词和 65.6% 的活跃 TF-IDF 特征，机器人概率却从 0.632 降至 0.212。高亮词分

布在多个句子和主题片段中，说明分类器依赖的是分散的局部贡献组合。

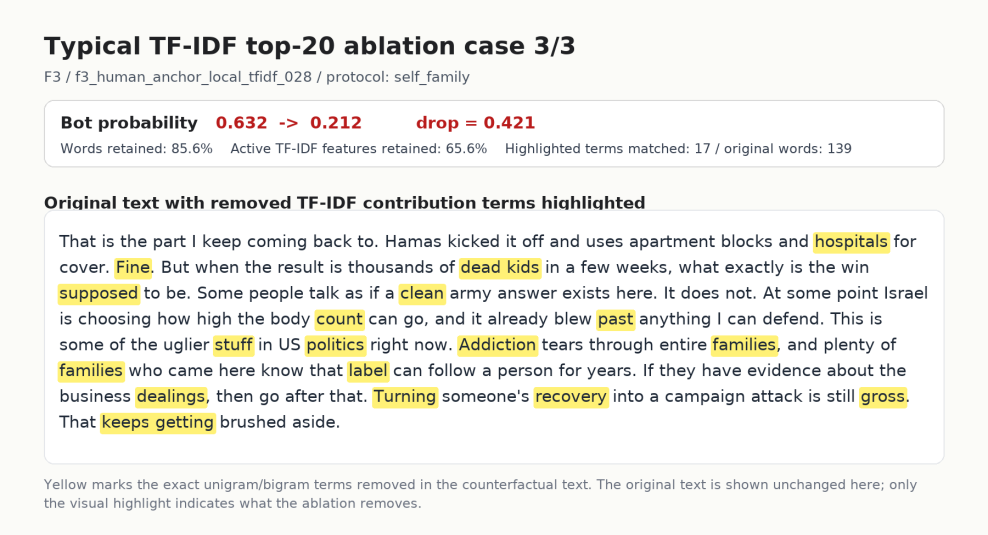


图 22: TF-IDF top-20 消融的典型 F3 样本。黄色仅标记反事实文本中将被删除的词项，图中原文保持不变。删除较少词项即可显著降低机器人概率，说明静态高分部分依赖少数高权重局部特征。

F.7 话题控制的精确结果

图 18 给出话题匹配后的总体趋势。表 8 列出具体数值。总体召回率为 0.988；在 Israel/Palestine、Russia/Ukraine、US politics 和 Law/rights 四类主题中，召回率均不低于 0.983。Other/mixed 桶下降到 0.941，但样本量只有 17。主题控制未消除 TF-IDF 的高召回，说明检测信号同时来自语言风格、短语组合和生成过程伪影。

表 8: 话题匹配控制下的 TF-IDF 机器人召回率。

主题桶	样本数	机器人召回率
总体	162	0.988
Israel/Palestine	60	0.983
Russia/Ukraine	15	1.000
US politics	53	1.000
Law/rights	17	1.000
Other/mixed	17	0.941

G 图结构实验的补充诊断

G.1 G1–G3 的图家族可分性

正文图 6b 报告了图家族分类混淆矩阵。其原始计数为

$$\begin{bmatrix} 28 & 15 & 7 \\ 19 & 16 & 15 \\ 7 & 17 & 26 \end{bmatrix},$$

其中行是真实 G1/G2/G3，列是预测 G1/G2/G3。G1 与 G3 各自保留一定对角信号，G2 大量分散到另外两个家族。三个 family 的行为机制确实改变了图特征，但它们在共享环境中相互作用后形成了较宽的重叠区域。这与 F1–F5 文本家族几乎完美可分的结果不同，说明共享环境能够削弱“一个 family 对应一个清晰图模板”的风险。

G.2 为何不同图检测器恢复速度不同

正文图 11b 显示，GraphStats LR 平滑恢复，EBM 在 5% 标签后快速上升，GraphSAGE 到 25% 左右才发生跃迁，RGCN 在极少标签时已经较高。表 9 从算法机制解释这些差异。

表 9: 标签稀缺曲线的算法机制解释。这里的“恢复”指加入少量新生成机器人标签后，对留出生成机器人的召回提升。

方法	表示瓶颈	恢复形态	机制解释
GraphStats LR	39 个左右的显式局部统计，经标准化后线性组合。	从 1% 标签开始平滑上升。	参数少，少量标签即可移动线性边界；若新 family 依赖非线性交互，恢复上限受到限制。
GraphStats EBM	显式统计的单变量非线性函数与少量二阶交互。	5% 后快速提升，随后保持高位。	新标签足以暴露阈值和局部交互，样本效率与表达能力较平衡。
GraphStats RF	多棵树对显式统计执行阈值切分。	极少标签时波动较大，标签增加后快速接近高召回。	能捕捉复杂 shortcut，但小样本树分裂不稳定，方差高于 LR/EBM。
GraphSAGE	同质化邻域聚合，关系类型被折叠。	低标签区接近零，达到约 25% 后突然跃升。	参数较多且监督信号需要通过邻域学习稳定表示；关系折叠使早期标签难以指出哪类互动最关键。
RGCN	带类型关系的消息传递。	1%–10% 标签区已经较高。	关系类型提供强归纳偏置，并能沿完整拓扑传播监督；同一优势也带来转导信息与关系 shortcut 风险。

G.3 G4 替位互动的详细 shortcut 审计

G4 让机器人进入原有人类互动位置，降低零入边、孤立节点和纯机器人组件等简单伪影。表 10 显示，G4 的外向互动仍以机器人到人类为主，低互惠账号占比达到 0.74。它比早期语言 family 更接近真实讨论图，同时留下“高入边、低互惠、特定一级/二级评论比例与方向平衡”的组合差异。

表 11 给出正文图 11a 的精确数值。GraphStats RF 和 EBM 对 G4 的召回率仍为 0.94 和 0.86，GraphStats LR、GraphSAGE 和 RGCN 则降至 0.00、0.00 和 0.04。该分化说明 G4 残留信号主要表现为非线性阈值与交互组合；依赖线性边界、同质邻域或旧关系模式的检测器难以直接迁移。

表 10: G4 替位互动家族的关键图统计。

指标	数值
低互惠账号占比	0.7400
机器人到机器人出边占比	0.1308
机器人到人类出边占比	0.8692
平均收到回复数	12.52

表 11: G1–G4 的 LOFO 机器人召回率。G4 是补充压力测试，不并入 G1–G3 主实验均值。

检测器	G1	G2	G3	G4
GraphStats LR	0.84	0.94	0.98	0.00
GraphStats RF	0.92	0.96	0.98	0.94
GraphStats EBM	0.90	0.94	0.98	0.86
GraphSAGE	0.94	0.98	1.00	0.00
RGCN	0.96	0.96	1.00	0.04

H　连续漂移实验的逐家族数值

H.1　同代留出家族迁移

正文图 12 展示同代 LOFO 热力图和增量代际恢复曲线。表 12 将每个同代 LOFO 单元格列出。TF-IDF 在多数 A/C/E 单元格中接近零；BGE 在第一代对 E 的迁移较强，但第二代对 E 降至 0.12；图检测器在第一代对三条谱系都较强，第二代和第三代则整体崩溃。由此可见，“代际更晚”和“检测更难”没有自动对应关系；检测难度由漂移轴、训练中可见的同代 family 和检测表示共同决定。

表 12: A/C/E 连续漂移实验的同代 LOFO 机器人召回率。每行是检测表示与目标谱系，三列分别为目标第 1–3 代。

检测表示	留出目标谱系	第 1 代	第 2 代	第 3 代
BGE	A（语言漂移）	0.38	0.50	0.38
BGE	C（图与记忆漂移）	0.62	0.50	0.38
BGE	E（混合涌现漂移）	0.88	0.12	0.38
TF-IDF	A（语言漂移）	0.00	0.00	0.00
TF-IDF	C（图与记忆漂移）	0.12	0.00	0.12
TF-IDF	E（混合涌现漂移）	0.00	0.00	0.00
图检测器	A（语言漂移）	0.62	0.00	0.00
图检测器	C（图与记忆漂移）	0.75	0.00	0.00
图检测器	E（混合涌现漂移）	1.00	0.00	0.00

H.2　增量代际恢复

增量协议在每一代加入此前生成 family，再测试下一代。表 13 显示，TF-IDF 与 BGE 的恢复趋势较清晰；GraphStats RF 到第三代显著上升，GraphStats LR 的轨迹则非单调。RGCN 变体第一代较强、后续接近零，说明完整关系表示也可能快速过拟合某一

代际的关系模式。

表 13: 连续漂移增量协议的平均目标机器人召回率。

检测器	第 1 代	第 2 代	第 3 代
TF-IDF	0.000	0.167	0.708
BGE	0.083	0.500	0.625
GraphStats LR	0.750	0.417	0.500
GraphStats RF	0.333	0.333	0.833
GraphStats-RGCN 变体	约 0.79	0.000	0.000

动态目标单元较小，每个谱系、每一代只有 8 个机器人。因此，表中数值用于展示协议和算法轨迹，不用于宣称稳定的总体性能排序。更稳健的后续工作应增加独立运行种子、扩大每代账号规模，并报告置信区间。

I 无监督机制簇发现的使用边界

正文图 13 展示 HDBSCAN 与 dense component scan 的探索结果。该流程包含四步。

1. 将账号文本映射到 TF-IDF 空间，并在发现阶段隐藏人机标签；
2. 使用 HDBSCAN 识别不同密度下稳定存在的账号簇，同时把无法稳定归簇的账号记为噪声；
3. 按簇稳定性、成员概率或 dense component 得分排序候选机制簇；
4. 只在事后揭示标签，计算候选簇的机器人纯度、精确率、召回率与 F1。

HDBSCAN 的输出包括簇编号、噪声标记、簇稳定性和个体成员概率。它回答的是“哪些账号形成了异常高密度的机制簇”，无法直接回答“每个账号是否为机器人”。本实验最佳 Top-9 F1 约为 0.527，召回约为 0.35–0.40，说明方法能够提供一批高相似候选，但仍会漏掉大量分散机器人。正文提出的人机协同流程因此把它放在候选发现阶段，通过聚类发现新分布，审核员检查少量代表样本，再把确认标签交给监督检测器增量恢复。

这一探索还有两项限制。第一，高密度也可能来自正常兴趣社区或事件驱动的语言同步，需要结合时间、图结构和人工语境判断。第二，即使标签只在评估阶段使用，发现流程仍可能受到向量化方式、最小簇大小和距离度量影响。后续研究应把机制簇稳定性、跨时间复现和人类审核一致性作为主要指标。